

具身智能 (Embodied AI) 文献综述

阅读说明：这是一篇写给零基础本科生的主题式文献综述。每个专业术语第一次出现时都会用大白话解释，大量使用类比和生活化例子。目标是让你读完能对这个领域有一个清晰的“认知地图”——知道它是什么、为什么重要、有哪些关键技术、目前走到哪了、还有什么没解决。

一、引言：AI 为什么需要“身体”？

想象一下，你让一个从没下过厨房的人做一道番茄炒蛋。你给他一份详细文字说明：“把番茄切块，打两个鸡蛋搅散，热油下锅……”他能做出来吗？大概率会搞砸——他不知道“切块”是多大的块，“热油”是多热的油，锅铲怎么握，什么时候翻面。

这就是今天最强 AI（比如 GPT-4、Claude）的困境。它们读过全世界的菜谱，能背诵番茄炒蛋的配料比例，但你真把它们接到一个机器人身上放进厨房，它们连打个鸡蛋都费劲。

为什么？因为**理解一件事和实际做一件事，是两回事**。

传统 AI 像一个“脑在缸里”的天才——它读过所有书，会解最难的数学题，但从未用自己的手摸过一个真实的物体。而**具身智能 (Embodied AI)** 的核心信念就是：**真正的智能不能只靠“想”，必须靠“做”**。智能必须有一个身体 (embodiment)，通过身体与真实世界的交互——看、听、摸、走、抓、推——才能形成对世界真正的理解。

这个想法听起来很直觉，对吧？但它在 AI 历史上其实是一个革命性的转折。接下来我们看看这场革命是怎么发生的。

二、定义与起源：具身智能从哪里来？

2.1 什么叫“具身”？——用身体思考

“具身” (embodied) 这个词可以拆开理解：**具 = 具备，身 = 身体**。一个具身的智能体，就是拥有物理身体、能够在真实世界里感知和行动的智能系统。

与之相对的，是传统 AI：它们没有身体，只能被动处理输入给它们的数据。比如一个图像识别模型，你给它一张猫的图片，它告诉你“这是猫”——它不需要去摸猫、追猫、抱猫，它只看图片。

具身智能不只是“AI + 机器人”这么简单，它的核心主张更深刻：**智能不是在大脑里单独产生的，而是大脑、身体和环境三者不断互动中涌现出来的**。

一个类比帮你想清楚：

你学骑自行车，没有人能通过看书学会。你必须上车，感受重心偏移，微调车把，摔倒，再爬起来。在这个过程中，你的“身体”教会了你大脑怎么控制平衡——这不是纯脑力劳动，而是身体在学习。

2.2 思想起源：从图灵到布鲁克斯

1950 年——图灵早就隐约想到了

AI 之父艾伦·图灵在他的经典论文《Computing Machinery and Intelligence》中，除了提出著名的"图灵测试"，还提出了一个不那么出名但极具远见的想法：也许应该造一台像孩子一样通过与世界互动来学习的机器（他设想给机器装上"最好的感官器官"，然后像教小孩一样教它）。这个想法后来被研究者称为"具身图灵测试"的雏形。但图灵本人当时还是把重点放在了纯智力测试上——他明确说"我们不必太关心腿、眼睛之类的东西"。

1980 年代——符号 AI 的困境

在具身智能出现之前，AI 的主流叫**符号 AI (Symbolic AI)**，它的想法是：智能就是符号运算——就像计算机处理 0 和 1 一样，大脑处理的是抽象的符号（比如"猫"这个概念就是一个符号）。你给 AI 定义好所有规则，它就能推理。

结果呢？这种 AI 在下象棋这种封闭系统中很厉害，但一遇到真实世界的模糊性就崩溃了——它不知道"红色的圆形水果"是苹果还是番茄，因为它从未见过实物。

1990 年——符号落地问题 (Symbol Grounding Problem)

认知科学家 Stevan Harnad 提出了一个灵魂拷问：**如果一个 AI 系统里所有的"含义"都只是符号之间的互相指代，那这些符号最终怎么和真实世界连接起来？**就像一本词典里只有词与词之间的互相解释，但没有任何一个词指向真实物体。这个问题被称为"符号落地问题"——它直接击中了传统 AI 的要害。

1991 年——布鲁克斯的革命：不需要表征的智能

这一年，MIT 教授 Rodney Brooks 发表了一篇划时代的论文——《Intelligence Without Representation》（没有表征的智能），被视为具身智能的奠基之作。

Brooks 做了一个非常简单但震撼的实验：他没有用复杂的推理和世界模型，而是造了几个像虫子一样的小机器人，每个机器人只有几条简单的行为规则（"碰到墙就转弯"、"看到光亮就走过去"）。结果这些"笨"机器人竟然展现出了非常自然的智能行为——它们在房间里自由穿行，躲避障碍，看起来就像是"理解"了环境。

Brooks 由此提出：**智能可以很简单——它来自于身体与环境的直接交互，根本不需要大脑里先建一个"世界的模型"。**这个想法后来被称为**行为主义机器人学 (Behavior-Based Robotics)**。

把布鲁克斯的想法用大白话总结：


你走路的时候，并没有在脑子里实时计算每一步的重心偏移和肌肉发力。你的身体"知道"怎么走。智能，很多情况下是身体自动处理的东西，不是大脑刻意想出来的。

2.3 具身智能 VS 传统 AI：一张表看懂

对比维度	传统 AI (无身体)	具身智能 (有身体)
核心比喻	大脑是一台计算机	智能是身体+大脑+环境的整体
与世界的关系	被动观察者，只看不碰	主动参与者，在做中学
如何学习	在静态数据集上训练	在持续交互中学习
典型例子	GPT-4、图像识别、AlphaGo	机器人、自动驾驶、智能义肢
致命弱点	符号落地问题——不理解真实世界	硬件贵、训练慢、数据难收集

三、核心理念：感知—行动闭环

具身智能最核心的运作模式可以用一个循环来描述：



这个循环叫**感知—行动闭环（Perception-Action Loop）**，是具身智能的命根子。

3.1 一个生活中的闭环

你在沙发上伸手去拿桌上的水杯：

1. **感知**：眼睛看到杯子的位置，手感觉到沙发的支撑
2. **决策**：大脑估算伸手的角度和力度
3. **行动**：手臂伸出，手指张开
4. **新感知**：手指碰到杯子，感觉到它的温度和重量
5. **新决策**：调整握力，别捏碎了
6. **新行动**：轻轻拿起

整个过程流畅到你根本没意识到——但每一次“感知→行动”之间的延迟只有几十毫秒，而且你的身体在不断地微调。**这就是具身智能的核心：不是一次性的“看→动手”，而是在动的过程中持续地看、持续地调整。**

3.2 为什么这个闭环如此重要？

回到“番茄炒蛋”的例子。传统 AI 是：你给它一张番茄的照片，它输出“番茄”两个字。输出完了，就结束了。它不会去摸一摸番茄熟了没有，也不会调整菜刀的角度。

具身智能的机器人做番茄炒蛋，过程是这样的：

- 它看到番茄，伸出机械臂去抓——但滑了，番茄滚走了
- **它看到番茄滚走了，重新调整抓取角度**
- 这次抓稳了，拿起来闻一闻（传感器反馈），放到砧板上
- 它拿起刀，感知到番茄的硬度，调整下刀力度
- 切开后，看到里面有点生，决定多炒一会儿

关键区别：传统 AI 做一次预测就结束了；具身智能在不断交互中实时调整。

3.3 经典的实验证明：小猫旋转木马

1963 年，两位心理学家 Held 和 Hein 做了一个著名的实验，常被称为“小猫旋转木马”（Kitten Carousel）。

他们让两只小猫共享同样的视觉体验——但一只猫**自己主动走**，另一只猫被放在篮子里**被动推着走**。两只猫看到的東西完全一样，区别只在于：**一只猫的行动（走）决定了它看到什么，另一只猫只能被动接受。**

结果：主动行走的小猫正常发育了视觉能力；被动推着走的猫，虽然也“看到”了一样的东西，却没有形成正常的视觉引导能力——它会撞墙，不会判断距离。

这个实验告诉我们：光有“看”是不够的。只有在“看”和“动”之间建立闭环，智能才能正常发育。这直接反驳了传统 AI 的“喂数据就能学”的思路。

四、技术路线（一）：强化学习——从试错中学习

4.1 基本思路

强化学习（Reinforcement Learning, RL）是最早让具身智能“学会行动”的方法之一。它的思路很简单：让机器人在环境里瞎试，做对了就奖励，做错了就扣分，慢慢学会怎么做才对。

类比：你训练狗坐下

你把狗粮握在手里，说“坐下”。狗狗一开始不知道要干嘛——它可能趴下、转圈、站起来。但当它偶然坐下的瞬间，你立刻给它零食（奖励）。几次之后，它明白了：“坐下 = 有吃的。”强化学习的原理一模一样：机器通过大量试错，找到那条连接“行动”和“奖励”的路。

4.2 关键里程碑

2013-2017：深度强化学习（Deep RL）崛起

DeepMind 把深度学习（用神经网络处理图像等复杂输入）和强化学习结合起来，做出了 DQN（深度 Q 网络），让 AI 自己学会打 Atari 游戏——只看屏幕像素，就学会了怎么玩。虽然这还不是“具身”的，但证明了“从交互中学习”这条路走得通。

2017：PPO（近端策略优化）——让 RL 变得稳定实用

Schulman 等人提出的 PPO（Proximal Policy Optimization，近端策略优化）成了强化学习的“标配算法”。它解决了之前 RL 像坐过山车一样不稳定的问题——训练过程更平滑，更容易调参。到今天，PPO 仍然是机器人 RL 训练的主力。

💡 强化学习的核心矛盾：探索 vs 利用

一个有趣的问题：机器人是一直用已经学会的最优策略（利用），还是偶尔试试新方法（探索）？如果它只“利用”，永远找不到更好的方法；如果它只“探索”，学到的技能永远沉淀不下来。这就像你每天走同一条路去教室（利用），但可能错过了一条更近的路——你得偶尔绕道试试（探索）。强化学习的算法设计很大程度上就是在权衡这个矛盾。

2018-2024：从仿真到真实的跨越

强化学习在真实机器人上直接训练效率极低——机器人摔几次就坏了。研究者们想到了一个窍门：**先在仿真环境里训练，再把学到的技能迁移到真实机器人上。**

这引出了两条并行的线索：

- **仿真器（simulator）** 越来越好：从 MuJoCo（2012，物理仿真引擎，快速精确）到 NVIDIA Isaac Sim（GPU 加速的大规模并行仿真），现在可以同时训练数千个虚拟机器人

- **Sim-to-Real (仿真到真实迁移)** 技术不断进步：通过在仿真中随机化各种参数（摩擦力、光照、重量），让机器人学会适应真实世界的随机性

五、技术路线（二）：模仿学习——看一遍就会

5.1 基本思路

强化学习有个大问题：**太慢了**。让机器人从完全随机开始试错，学会“拿杯子”可能需要几百万次尝试。

模仿学习 (Imitation Learning, IL) 的思路完全不同：**我不让机器人瞎试，我直接做一遍给它看，让它照着学。**

类比：学跳舞

强化学习相当于你把自己关在舞蹈房里，自己瞎跳几万遍，通过无数次摔倒学会一支舞。

模仿学习则是：老师跳一遍，你跟着跳——比你一个人瞎试快得多。

5.2 主要方法

行为克隆 (Behavioral Cloning, BC)：最直接的模仿——人操作机器人做任务（比如“拿杯子”），同时记录下摄像头看到的画面和机械臂的动作。然后用这些“画面→动作”的数据训练一个神经网络。训练完后，输入摄像头画面，网络直接输出机械臂该怎么做。

DAgger (Dataset Aggregation, 数据集聚合)：行为克隆有个问题——如果机器人做错了一点点，就会进入一个“从来没见过的状态”，这时候它就完全不知道该怎么办了（就像背了答案但题目稍微变一下就懵了）。DAgger 的改进是：机器人自己做的时候如果做错了，人类再纠正它，把纠正的数据也加进训练集。如此反复，机器人的表现会越来越好。

5.3 为什么今天模仿学习这么火？

因为**数据收集变得更容易了**。过去你要给机器人编程才能让它动；现在研究者可以戴上 VR 头盔，用手柄远程操控机器人做任务，同时把所有的“眼（摄像头）→手（机械臂动作）”数据录下来。一个人一天可以收集几百次演示的数据。

有两个大型数据集直接推动了近年的突破：

- **Open X-Embodiment (2023)**：22 种不同的机器人、21 个机构、160,000 多个任务的协作数据集。
影响：让一个模型可以学会操作多种不同的机器人。
- **DROID (2024)**：横跨北美、亚洲、欧洲，在家庭和办公室等真实环境里收集的 76,000 条操作数据。
影响：大幅提高了模型在新环境中的泛化能力（**泛化**，读作 fàn huà，就是模型把在训练中学到的能力应用到没见过的新场景中的本事——好比你会骑一辆自行车，换一辆也能骑，这就叫“泛化得好”）。

六、技术路线（三）：世界模型——在大脑里“预演”

6.1 基本思路

你有没有在脑子里“演练”过一件事——比如明天面试时要说的话？你会在想象中过一遍流程，设想面试官会问什么，你该怎么回答。如果想象中某个回答不合适，你还可以在脑子里换一个——**你不需要真的去面试一次才能改进。**

世界模型 (World Model) 做的就是这件事：让机器人在自己的“大脑”里建立一个对世界的模拟（即“世界模型”），然后在模型里“想象”各种行动的结果，选择最好的一种再在现实中执行。

类比：象棋高手的大脑

象棋高手不是真的在棋盘上试每一步——他在脑子里“算棋”，推演对手可能的回应，然后选择最优走法。世界模型就是给了机器人同样的“心算”能力。

6.2 关键里程碑

2018: Ha & Schmidhuber 的《World Models》——奠基之作

David Ha 和 Jürgen Schmidhuber 证明了一个简单但强大的想法：让一个 AI 先是观察环境（比如开车游戏），在它的大脑里学会预测“如果我左转，画面会变成什么样”。然后，它可以在自己的“梦境”中练习开车，练好了再回到真实环境中。结果：**光是靠“做梦”练习，就学会了真实开车。** 这篇论文点燃了世界模型这个方向。

2019-2023: Dreamer 系列——世界模型的强化学习

Danijar Hafner 的 Dreamer 系列 (Dreamer、DreamerV2、DreamerV3) 把世界模型和强化学习结合了起来。DreamerV3 (2023) 用一套固定的参数就能在 150 多种不同任务上取得顶尖表现——从简单的平衡游戏到复杂的 Minecraft 挖钻石。

2022: LeCun 的 JEPA 架构——不预测像素，预测“含义”

Yann LeCun 提出，传统世界模型有个问题：它试图预测每一个像素下一帧会变成什么样，这太浪费算力了（就像你要预测明天天气，结果去预测每一片树叶的运动，没必要）。他的 **JEPA (联合嵌入预测架构)** 思路是：不预测像素，而是预测像素的“抽象含义”（比如：物体的位置、速度、形状）。效率高得多。

2025: V-JEPA-2——零样本机器人规划

Meta 的 V-JEPA-2 在 100 万+小时的视频上做自监督训练（**自监督**，模型自己给自己出题——不需要人手工标注数据，直接让模型预测视频的下一帧来学会理解画面），然后用仅 62 小时的机器人数据微调（**微调**，在一个已经学会通用能力的模型上，用少量任务-specific 数据做“最后一跳”，让它学会特定技能——就像你已经会开车了，换一辆新车只需要适应一下刹车和油门的脚感），就能在**从未见过的环境中**规划机器人动作。它在 HuggingFace 的物理推理基准上排名第一，超过了 GPT-4o。

2025: PEVA——第一人称 16 秒连贯预测

LeCun 团队的最新成果 PEVA 从第一人称视角预测 16 秒内的场景变化——这是目前具身世界模型中最长的连贯预测。它放弃简单的“左/右”控制信号，直接预测全身动作轨迹。

6.3 为什么世界模型是未来的关键？

世界模型解决了一个核心矛盾：**真实世界的数据太贵了。** 机器人在真实世界里走一步就需要花一秒，摔坏了还要修。但在模型里，它可以运行得比真实世界快 100 倍，经受无数次虚拟试错而不损坏任何硬件。

一句话总结：世界模型 = 给机器人一个可以无限“做梦训练”的虚拟世界。

七、技术路线（四）：VLA 大模型——看见、理解、行动


如果说世界模型是让机器人学会“脑补”，那 VLA（Vision-Language-Action，视觉-语言-动作）大模型就是让机器人学会“读指令、看东西、干事情”三位一体。

7.1 从 LLM 到 VLA：一条清晰的进化链

第一步：LLM 大语言模型（如 GPT-4）——只懂文字，没有眼睛，没有手。能写诗但不会倒水。

第二步：VLM 视觉语言模型（如 GPT-4V）——长了眼睛，能“看懂”图片，但依然没有手。能描述图片里的水杯，但拿不起来。

第三步：VLA 视觉-语言-动作模型——既有眼睛（摄像头），又能理解人类语言指令，还会操作身体（机械臂/机器人）。你说“把桌上那杯水拿给我”，它看到杯子，理解你的话，伸臂抓住杯子递过来。



类比：三个阶段的区别

- LLM：一个盲人文学教授，知识渊博但看不见摸不着
- VLM：一个戴上眼镜的评论家，能看懂但不动手
- VLA：一个会做饭、会打扫、会修东西的全能管家

7.2 关键里程碑

2022：SayCan——让大语言模型指挥机器人

Google 的 SayCan 是第一个让大语言模型（LLM）指挥真实机器人的系统。思路很聪明：LLM 擅长理解用户意图（“我运动完了，帮我拿点吃的”），但 LLM 不知道机器人**实际能做什么**（比如机器人可以抓杯子但够不到冰箱上层）。SayCan 把 LLM 的“语言理解”和机器人的“实际能力”结合起来——LLM 说理想方案，机器人的能力模块说“我能做到什么程度”，两者取交集。

2023：PaLM-E——把传感器数据直接喂给大模型

Google 的 PaLM-E 是一个“具身多模态语言模型”（**多模态**，能同时处理多种类型的信息——比如文字、图片、声音、传感器数据。人就是多模态的：你用眼睛看、耳朵听、手去摸，同时处理好几种信息），它把摄像头画面和机器人状态（比如机械臂的角度）直接作为输入，和大语言模型的文字输入拼接在一起。PaLM-E 可以回答“我面前有什么”，也可以规划“先拿杯子再倒水”。

2023: RT-2——VLA 的诞生

如果说 PaLM-E 还是“大模型负责想，别的模块负责做”，那 Google DeepMind 的 **RT-2** 就是第一个真正意义上的端到端 VLA 模型（**端到端**，输入一头（摄像头画面）直接输出另一头（电机指令），中间没有拆成“先识别物体→再规划轨迹→最后算角度”这样的独立模块）。它做了一个聪明的小改动：把“动作”也变成一种“语言”。机械臂的动作（向左移动 5 厘米）被编码成类似文字的 token（**token**，AI 处理信息的最小单元——文字被切成词或子词，图片被切成小块，动作被切成离散的档位，每个小块就是一个 token，就像把一句话拆成一个个字或者词来处理），和互联网上的图片、文字一起训练。结果：**机器人通过看互联网上的图片，就学会了它从未被直接训练过的新技能**。比如 RT-2 没见过“把苹果放到同色的杯子里”，但它能推理出来——因为它从网上图片里学过了“红色杯子”和“苹果是红色的”这些概念。

2024: OpenVLA——把 VLA 开源，人人都能玩


之前 RT-2 是 Google 的内部系统，不开源。斯坦福和 UC Berkeley 的 **OpenVLA** 是第一个完全开源的 VLA 模型。OpenVLA 只有 70 亿参数（比 RT-2 的 550 亿小得多），但因为训练数据更丰富（97 万次机器人演示），效果反而更好。更关键的是，你可以在消费级 GPU 上用几十条数据微调它，让它学会操作你自己的机器人。

2024: π_0 (Pi-Zero) ——连续流畅的动作

物理智能公司（Physical Intelligence）的 π_0 解决了之前 VLA 的一个关键问题：之前的 VLA 把动作离散化成“向左 5cm”这样的一档一档的，导致动作很僵硬。 π_0 用“流匹配”（flow matching，一种生成连续动作的技术）来输出平滑、自然的动作——它不需要把动作“数字化”。结果： π_0 能够完成叠衣服、清桌子、打包纸箱这种需要精细控制的任务。训练数据：10,000+ 小时的机器人操作数据，覆盖 7 种不同机器人。

2024: GR-2——用视频预训练弥补数据不足

字节跳动的 **GR-2** 走了一条新路：先让模型在 3800 万段人类视频上做“视频预测”预训练（给定当前画面，预测下一帧），然后再用机器人数据微调。预训练的好处是：视频数据到处都是（YouTube、短视频），不需要专门去收集机器人数据。GR-2 在一个包含 105 个任务的测试上达到了 97.7% 的成功率。



八、载体：机器人的“身体们”

具身智能需要身体，而不同的身体适合不同的事情。就像人有不同的工种，机器人也有不同的形态。

8.1 机械臂

最简单也最成熟的载体。一个固定在底座上的手臂，通常有 6-7 个关节自由度（**自由度**是指可以独立运动的轴的个数，类比人类的肩膀、肘、手腕各有不同的活动方向）。

- **代表平台：** Franka Emika Panda、Kinova Gen3、KUKA LBR iiwa
- **擅长：** 桌面操作（抓取、放置、组装、插拔）
- **局限：** 无法移动，只能在一个固定范围内工作

8.2 四足机器人

有四条腿，像狗或猫一样行走。

- **代表平台：** Boston Dynamics Spot、Unitree Go2/宇树科技、ANYmal
- **擅长：** 在不平整的地形上行走（楼梯、碎石路）、工业巡检、地图探索
- **为什么是四条腿：** 比两腿稳定得多，即使滑了一下也能快速恢复平衡
- **为什么不是轮子：** 腿可以跨越障碍（比如台阶），轮子不行

8.3 人形机器人

两条腿，两只手，和人长得差不多。

- **代表平台：** Boston Dynamics Atlas、Tesla Optimus、Figure 01/02、Unitree H1
- **为什么做人形？** 我们的世界是为人类身体设计的——楼梯、门把手、工具、椅子。人形机器人理论上可以无缝使用所有人类工具。不需要改造工厂。
- **代价：** 双足行走极其困难（地球上的两足动物只有人类和鸟类，因为维持平衡极其复杂）

2024-2025 的关键进展：

- **Boston Dynamics Atlas：** 2024 年推出全电动版的 Atlas（放弃了之前的液压版）。2025 年，BD 与丰田研究所（TRI）合作开发了大型行为模型（Large Behavior Model），用一个神经网络同时控制行走和操作。Atlas 可以在受到人为干扰时**自动调整**（比如你关上它正在整理的箱子，它会自己重新打开整理）。
- **Tesla Optimus：** 2024 年展示在工厂里分类电池、搬运箱子的能力。
- **Figure 01：** 接入了 OpenAI 的大模型，能用自然语言与人交流，理解指令并执行。

8.4 仿真环境（模拟器）

关键比喻： 仿真环境是机器人训练的“虚拟驾校”。

你不能让学员直接上车路上练，太危险。你先让他在模拟器里练习各种路况、天气、突发情况。等练熟了再上路。

具身智能的仿真环境：

- **MuJoCo (2012)：** 高效的物理引擎，广泛用于强化学习。开源后被 DeepMind 维护。
- **Habitat (2019, Meta)：** 专注于**导航**——让虚拟机器人在照片级真实的 3D 房间里行走。
- **NVIDIA Isaac Sim (2024)：** 目前最强大的仿真平台，支持 GPU 加速的大规模并行训练——可以同时训练数千个虚拟机器人。集成了物理模拟、传感器仿真、域随机化（在训练中随机改变环境参数，提高迁移到真实世界的成功率）。

- SAPIEN、AI2-THOR、Maniskill2：专注于操作任务的仿真环境。

8.5 各类载体对比一览

类型	稳定性	机动性	操作能力	成本	典型应用
机械臂	★★★★★	★（固定底座）	★★★★★	中等	工厂产线、实验室操作
轮式底盘+臂	★★★★★	★★★★★	★★★★★	中高	仓储物流、酒店配送
四足机器人	★★★★★	★★★★★	★★（无手/简单夹爪）	高	巡检、勘探、救援
人形机器人	★★	★★★★（能走楼梯）	★★★★★（拟人）	极高	通用家务、工业操作（研究中）
无人机	★	★★★★★（空中）	★	中低	测绘、巡检、农业喷洒

通俗理解：没有完美的载体。机械臂像工厂老师傅——专精但离不开工位；四足像侦察兵——翻山越岭但不擅长动手；人形是终极目标——什么都能干，但现在还“站不稳”。选哪款取决于你要解决什么问题。

九、应用场景与当前挑战

9.1 已经在做和即将能做的事

领域	当前能力	代表系统	商用成熟度
工业制造	零件分拣、螺丝拧紧、产品检测	各大汽车/电子工厂的机械臂	✅ 已大规模部署
仓储物流	包裹搬运、货物上架	Amazon 的仓储机器人、Dexterity	✅ 已大规模部署
自动驾驶	城区道路、高速领航辅助	Waymo、Tesla FSD、百度 Apollo	⚠️ 部分商用，L4 仍在扩展
家庭服务	叠衣服、清桌子、拖地	πo、TRI 的洗菜机器人	🔬 实验室阶段
医疗	手术辅助、康复训练	达芬奇手术系统、智能义肢	⚠️ 部分商用（手术）/ 研发中（康复）
探索巡检	地震废墟搜索、管道检测、核电站检查	Spot（四足）、ANYmal	⚠️ 小规模商用
农业	水果采摘、喷洒、除草	各类农业机器人	🔬 实验室/试点阶段

9.2 四大核心挑战

① 数据饥渴——真实数据太贵了

要让一个机器人学会“抓杯子”，你可能需要几千次演示。相比之下，训练 GPT-4 可以从互联网上免费抓取数万亿字的文本。

- 收集机器人数据需要人力（操作员一个个演示），费时费力
- 机器人在真实世界中运行慢、磨损快
- 每次换一种机器人，数据基本要重新收集

解决办法的方向：视频预训练（GR-2 的做法——先用人类视频学常识，再用少数机器人数据微调）、仿真训练（世界模型里“做梦”）。

② Sim-to-Real 鸿沟——仿真里会了，到现实就废了

机器人可能在仿真中完美学会走路，但一到真实地面就摔倒。原因是仿真永远是“近似”的——它无法完全模拟真实的摩擦力、光线变化、接触形变等物理细节。

解决办法的方向：域随机化 (Domain Randomization) ——在仿真中随机改变各种参数，让机器人学会适应各种可能的情况，从而覆盖真实世界的多样性。

③ 泛化能力弱——换个场景就不行了

大多数机器人是“温室里的花朵”——在实验室里表现完美，换个房间、换个光照条件、换个物体颜色，成功率就断崖式下跌。

解决办法的方向：大规模多任务训练 (Open X-Embodiment、DROID 的思路——让模型看过足够多的变化，学会真正的“通用技能”)。

④ 精细操作——折个纸都难

人类的手指有 20+ 个自由度，可以做极其精细的操作（穿针引线、剥鸡蛋、折纸飞机）。今天的机械手还远远达不到这个水平。

解决办法的方向：触觉传感器（让机器手有“触感”）、灵巧手设计、高精度控制算法。

十、新手如何入门：一条可操作的学习路径

如果你读完前面九章觉得“这个方向有意思，想自己动手试试”，这一节就是为你准备的。别被那些炫酷的论文和复杂的公式吓到——每个做这个方向的人都是从零开始的。以下是一条经过验证的学习路径，按顺序来就行。

一句话心态建设：不需要全部学会再开始动手。先跑通一个最简单的 demo，再回头补理论。动手是最快的入门方式。

10.1 先打好什么基础？

你不需要成为所有领域的专家。以下是最低必要知识，以及你需要掌握到什么程度：

① Python (必须, ★★★)

这是机器人学界的“普通话”。几乎所有工具、框架、仿真器都用 Python 接口。你需要：

- 基础语法（变量、循环、函数、类）——大一水平就够了
- `numpy`（数组和矩阵运算）——绕不开，RL 算法的每一步都在用
- 会看 `pytorch` 代码——不需要从零写，能读懂、能改就行

怎么学：找一份 Python 入门教程花 1-2 周过一遍基础语法，然后直接上手项目，遇到不会的再查。

② 线性代数 (★★☆)

机器人学本质上是空间几何。你需要理解：

- 向量、矩阵、矩阵乘法（神经网络的前向传播也就是一连串矩阵乘法）
- 坐标系变换（这就是机器人运动学的基础——机械臂的每个关节都对应一个坐标系）
- 不需要：纯数学证明、高维张量分解、泛函分析

怎么学： 3Blue1Brown 的《线性代数的本质》系列视频（B 站有搬运），花一个周末看完。比上课有用十倍。

③ 概率与统计 (★★☆)

强化学习的核心是处理不确定性。

- 概率分布、期望、条件概率、贝叶斯定理
- 你会反复遇到的概念：概率密度函数 (PDF)，但用到时再查就行

④ 深度学习基础 (★★★)

不需要成为深度学习专家，但需要理解：

- 神经网络是怎么训练的（前向传播 → 算损失 → 反向传播 → 更新权重）
- 常见的网络结构：CNN（处理图像）、Transformer（处理序列，也是 VLA 模型的基石）
- 过拟合是什么、训练/验证/测试集怎么分

怎么学： 李沐的《动手学深度学习》（d2l.ai）前 10 章，或者吴恩达的深度学习课程前 3 门。

⑤ 一点机器人学常识 (★☆☆)

- **自由度 (DOF)：** 机器人可以独立运动的轴的个数。你的手臂从肩膀到手腕有 7 个自由度。
- **正运动学：** 已知每个关节的角度，求手的位置。
- **逆运动学：** 已知手要到达的位置，反推每个关节应该转多少度。
- 不需要很深——用仿真器时会自动帮你算。

10.2 推荐入门课程/教材

公开课（免费的，有中文字幕）：

课程	谁讲的	为什么推荐
CS188 Intro to AI (UC Berkeley)	Pieter Abbeel 等	第一章讲搜索、最后几章讲强化学习和机器人，节奏好、作业设计精良
CS285 Deep RL (UC Berkeley)	Sergey Levine	深度强化学习最好的入门课之一，前几节从基础 RL 讲起，不需要太多先修
MIT 6.4210 Robotic Manipulation	Russ Tedrake	讲机器人操作的基础，附有配套的仿真作业，在 Drake 仿真器上跑
李沐《动手学深度学习》	李沐	第 11 章讲强化学习，但更重要的是前面十几章让你快速上手深度学习

经典教材/讲义：

- **Sutton & Barto 《Reinforcement Learning: An Introduction》**——强化学习的“圣经”，第二版免费在线可读。但建议：先看课，再把它当字典查。
- **《Robot Learning》by Peters et al.**——比上面那本更贴近机器人学的 RL 教材。

10.3 上手就能玩的仿真环境

这是关键：**不要在真实机器人上入门，太贵、太慢、太容易坏。** 先用仿真器。

如果你是纯新手，从这里开始：

环境	难度	推荐理由	链接
Gymnasium (原 OpenAI Gym)	★	MuJoCo 环境集, 30 分钟就能跑通一个 RL demo。控制一个虚拟蚂蚁学会走路, 经典的"Hello World"	gymnasium.farama.org
Isaac Lab / Isaac Sim	★★★★	NVIDIA 出品, 功能最强大, 但也最复杂。支持大规模并行训练。如果你想认真做研究, 这是最终要去的地方	developer.nvidia.com/isaac-sim
Habitat (Meta)	★★	专注于导航任务——让虚拟机器人在照片级真实的 3D 房间里行走、找东西。跑通示例只需要 15 分钟	aihabitat.org
Maniskill2	★★	专门用来训练机械臂操作（抓取、推、插拔）。和真实的 Franka 机械臂对应, 代码可以直接迁移到真机	maniskill.ai

我的建议：先装 Gymnasium, 运行「HalfCheetah-v4」或「Ant-v4」环境, 用 Stable-Baselines3（一个预写好的 RL 算法库, pip install 就能用）跑一个 PPO 训练。看到那个虚拟动物从原地打转到最后学会奔跑, 你的"入门仪式"就完成了。

```
# 你的第一个具身智能程序——不夸张, 就这么几行
pip install gymnasium stable-baselines3
```

```
import gymnasium as gym
from stable_baselines3 import PPO

env = gym.make("Ant-v4", render_mode="human") # 一只虚拟蚂蚁
model = PPO("MlpPolicy", env, verbose=1)      # 用 PPO 算法训练
model.learn(total_timesteps=100000)          # 跑 10 万步（一个下午的量）
model.save("ant_ppo")                        # 保存训练好的模型
```

10.4 第一个"小项目"建议

项目名称：在仿真中训练机械臂抓取杯子

这是具身智能最有代表性的任务——感知+规划+控制一条龙。

步骤：

1. **搭建环境：**装 Maniskill2 或 Isaac Lab, 加载一个"reach"任务（机械臂只需要把末端伸到目标位置, 不需要抓）
2. **跑通一个预训练好的策略：**用项目提供的预训练模型, 看它怎么工作的
3. **修改目标：**把"reach"改成"push"（推一个物体）, 调整奖励函数
4. **命令行参数调优：**改变学习率、训练步数等超参数, 观察效果变化
5. **升级：**换成"grasp"任务, 加上视觉输入, 用模仿学习从人类演示数据中学习
6. **可选：**换成 OpenVLA, 在仿真里跑一个真正的 VLA 模型

重要提醒： 前 3 步完成就算入门成功了。不要试图一步到位——抓取一个物体看似简单，但涉及到视觉识别、深度估计、逆运动学解算、抓取位姿规划、力控制，每一步都可以写一篇论文。

10.5 跟进前沿的渠道

关键会议（每年必看）：

会议	全称	方向侧重	入门友好度
CoRL	Conference on Robot Learning	机器人学习，近年 VLA 论文扎堆	★★★
RSS	Robotics: Science and Systems	顶级机器人学会，偏理论	★★
ICRA	IEEE Intl. Conf. on Robotics and Automation	最大的机器人学会议，全覆盖	★★★
IROS	IEEE/RSJ Intl. Conf. on Intelligent Robots	和 ICRA 差不多，每年和 ICRA 交替	★★★
NeurIPS	Neural Information Processing Systems	AI 顶会，RL 和具身智能论文越来越多	★★

我的建议： 初学者别追论文。去 YouTube 看 CoRL 和 RSS 的 **tutorial** 和 **workshop** 视频。这些是专门写给入门者的，比主会论文好懂十倍。

值得关注的团队/个人：

团队	机构	代表作/方向
Sergey Levine / Chelsea Finn	UC Berkeley	VLA 模型（RT-2、OpenVLA 合作方）
Fei-Fei Li 团队	Stanford	具身智能 + 空间智能
Russ Tedrake	MIT / TRI	机器人操作、运动规划
Pieter Abbeel	UC Berkeley	机器人学习、模仿学习
Yann LeCun 团队	Meta FAIR	世界模型、JEPA 系列
Physical Intelligence	创业公司	π_0 系列，通用机器人基础模型
Google DeepMind Robotics	Google	RT 系列、SayCan、PaLM-E
王鹤 / 高阳	北京大学	具身智能操作、扩散策略

公众号/博客（中文）：

- **机器之心、量子位**——跟进具身智能新闻资讯
- **李沐的论文精读系列**——如果他解读了某篇具身智能论文，那是入门最佳方式
- **知乎上搜“具身智能”**——有不少国内研究者的科普文章

10.6 一个常见问题：我没有机器人，能入门吗？

能。而且大部分人都是这样开始的。

现在的仿真环境已经足够逼真。Habitat 的场景基于真实 3D 扫描，Isaac Sim 的物理引擎可以模拟真实材料的变形，MuJoCo 的接触动力学精确到可以用在真实机器人的控制算法中。

很多顶会论文的算法就是在仿真里验证的，然后零修改迁移到真实机器人（这叫 Sim-to-Real Transfer）。

一句话：仿真入门，真实验证，这是具身智能研究的标准路线。

10.7 学习路径总图（一目了然）

第 1 个月：打好基础

- Python + numpy (2 周, 边用边学)
- 3Blue1Brown 线性代数视频 (1 周末)
- 吴恩达深度学习第 1-3 门课 (2 周, 快速过)
- CS188 前 5 讲 (1 周)

第 2 个月：跑通第一个 RL demo

- 装 Gymnasium + Stable-Baselines3 (半天)
- 跑通 Ant-v4 PP0 训练 (半天)
- 看 CS285 前 6 讲, 理解 PP0 的原理 (1 周)
- 改代码: 换环境、调参数、加网络层 (1 周)

第 3 个月：做一个仿真操作项目

- 装 Maniskill2, 跑通 reach 任务 (2 天)
- 改成 push 任务, 自己写奖励函数 (1 周)
- 看 OpenVLA 的 demo, 跑一个预训练模型 (1 周)
- 阅读一篇近期 CoRL 论文的博客解读 (持续)

第 4 个月以后：深入自己感兴趣的方向

- VLA 方向 → 读 RT-2 / OpenVLA 论文, 尝试在仿真上微调
- 世界模型 → 读 DreamerV3 论文, 跑代码
- 灵巧操作 → Maniskill2 上做 grasp 任务
- 跟着实验室节奏, 也许开始做自己的小项目

十一、开放问题与未来展望

11.1 当前最大的几个开放问题

1. 架构之争：端到端 VS 模块化

当前的具身智能系统有两个流派：

- **端到端 (End-to-End)**：一个巨大的神经网络，从摄像头画面直接输出电机控制信号。优点：整体优化，不存在中间误差累积。缺点：黑箱，出了问题难以调试（就像你无法问一个人的小脑“为什么要摔倒”）。
- **模块化 (Modular)**：拆分成感知模块、规划模块、控制模块，各自独立。优点：每个模块可以单独调试、更换。缺点：模块之间的信息传递会丢失细节。

目前行业共识是：**需要结合两者**——用大模型做高层规划（“先拿杯子，再倒水”），用轻量级网络做底层控制（具体的抓取轨迹）。

2. 安全性问题

当机器人进入家庭、医院、工厂，它们会和人近距离接触。一个 200 斤的人形机器人如果失控摔倒，可能造成严重伤害。如何在保证机器人学习能力的同时确保安全性？这还没有很好的答案。

3. 终生学习 (Lifelong Learning)

现在的机器人学会一个技能后，学新技能常常会“忘记”旧技能（**灾难性遗忘**，Catastrophic Forgetting）。就像你背了新的单词却忘了旧的。如何让机器人像人一样不断积累技能，而不忘记已有的能力？

4. 评估标准不统一

CV（计算机视觉）有 ImageNet，NLP（自然语言处理）有 GLUE，但具身智能还没有公认的标准化评估基准。你很难说“这个机器人比那个机器人好 10%”，因为涉及的环境、任务、硬件都不同。

11.2 展望：未来 3-5 年

短期（1-2 年）： VLA 模型将从“科研玩具”走向“实用工具”。机器人密度最高的行业（汽车制造、电子组装、仓储物流）将是第一批大规模部署的领域。

中期（3-5 年）： 世界模型 + VLA 的融合。机器人将拥有“想象”能力——在执行任务前先在脑中推演最佳方案。这会让机器人的适应性大幅提升。

长期（5-10 年）： 通用家庭机器人。能像人一样学会处理各种家务——但请注意，这仍然是**如果**而不是**当**。每一步突破都需要工程和科学层面上的跨越。

参考文献

以下文献均为经过 Semantic Scholar 核实过的真实出版物。

奠基性工作 (Foundational)

1. **Turing, A. M.** (1950). Computing Machinery and Intelligence. *Mind*, 59(236), 433-460. — 提及“儿童机器”设想，被后人视为具身智能概念的思想源头
2. **Brooks, R. A.** (1991). Intelligence Without Representation. *Artificial Intelligence*, 47(1-3), 139-159. [Semantic Scholar](#) — **具身智能的奠基论文**，提出行为主义机器人学
3. **Harnad, S.** (1990). The Symbol Grounding Problem. *Physica D*, 42(1-3), 335-346. — 符号落地问题，传统 AI 的根本困境
4. **Varela, F. J., Thompson, E., & Rosch, E.** (1991). *The Embodied Mind: Cognitive Science and Human Experience*. MIT Press. — 具身认知的经典著作
5. **Pfeifer, R., & Bongard, J.** (2006). *How the Body Shapes the Way We Think*. MIT Press. — 证明物理身体塑造了认知方式

强化学习与世界模型

6. **Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O.** (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347. — PPO 算法
7. **Ha, D., & Schmidhuber, J.** (2018). World Models. arXiv:1803.10122. [Semantic Scholar](#) — **世界模型奠**

基之作

8. **Hafner, D., et al.** (2023). Mastering Diverse Domains through World Models (DreamerV3). arXiv:2301.04104. [Semantic Scholar](#) — 通用世界模型
9. **LeCun, Y.** (2022). A Path Towards Autonomous Machine Intelligence. arXiv:2211.10831. — JEPA 架构提出
10. **Assran, M., et al.** (2025). V-JEPA-2: Video Joint-Embedding Predictive Architecture 2. arXiv:2506.09985. — 零样本机器人规划

VLA 大模型与基础模型

11. **Ahn, M., et al.** (2022). Do As I Can, Not As I Say: Grounding Language in Robotic Affordances (SayCan). *CoRL 2022*. arXiv:2204.01691. [Semantic Scholar](#) — LLM+机器人能力结合的开山之作
12. **Driess, D., et al.** (2023). PaLM-E: An Embodied Multimodal Language Model. *ICML 2023*. [Semantic Scholar](#) — 具身多模态大模型
13. **Brohan, A., et al.** (2023). RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. arXiv:2307.15818. [Semantic Scholar](#) — VLA 诞生之作
14. **Kim, M. J., et al.** (2024). OpenVLA: An Open-Source Vision-Language-Action Model. arXiv:2406.09246. [Semantic Scholar](#) — 首个开源 VLA
15. **Black, K., et al.** (2024). π_0 : A Vision-Language-Action Flow Model for General Robot Control. arXiv:2410.24164. [Semantic Scholar](#) — 流匹配 VLA
16. **Cheang, C.-L., et al.** (2024). GR-2: A Generative Video-Language-Action Model with Web-Scale Knowledge for Robot Manipulation. arXiv:2410.06158. — 视频预训练 VLA

仿真与数据集

17. **Todorov, E., Erez, T., & Tassa, Y.** (2012). MuJoCo: A Physics Engine for Model-Based Control. *IROS 2012*. [Semantic Scholar](#) — 物理仿真引擎
18. **Savva, M., et al.** (2019). Habitat: A Platform for Embodied AI Research. *ICCV 2019*. [Semantic Scholar](#) — 具身 AI 仿真平台
19. **Open X-Embodiment Collaboration** (2023). Open X-Embodiment: Robotic Learning Datasets and RT-X Models. *ICRA 2024*. arXiv:2310.08864. — 跨机构机器人数据集
20. **Khazatsky, A., et al.** (2024). DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset. *RSS 2024*. arXiv:2403.12945. — 大规模真实环境机器人数据集

综述与展望

21. **Paolo, G., et al.** (2024). A Call for Embodied AI. *ICML 2024 Workshop*. arXiv:2402.03824. — 具身 AI 作为通向 AGI 的必要路径
22. **Feng, Y., et al.** (2025). Embodied AI: From LLMs to World Models. arXiv:2509.20021. — LLM 驱动 vs 世界模型驱动的对标综述

23. Liu, Y., et al. (2024). Aligning Cyber Space with Physical World: A Comprehensive Survey on Embodied AI. arXiv:2407.06886. — 具身智能综述

附一：一页纸速览（全文精华 8 条）

- 1. **具身智能的核心主张：**真正的智能不能只靠"纯脑力"（处理数据），必须在真实世界中通过身体去感知、行动、反馈，才能形成对世界的真正理解。**"脑在缸里"的天才永远不如一个会摔倒会爬起来的机器人。**
- 2. **和传统 AI 的根本区别：**传统 AI 是"喂数据、做预测"，具身智能是"动手试、看结果、再调整"。关键在于**感知—行动闭环**——不是在脑海中一次性地想好再动手，而是在动手的过程中不断看、不断调。
- 3. **四条技术路线各司其职：****强化学习**靠大量试错自己摸索（慢但通用），**模仿学习**照人的演示做（快但依赖数据），**世界模型**在虚拟大脑里预演未来（省成本），**VLA 大模型**让机器人"看见+听懂+直接动手"（当前最火的方向）。
- 4. **VLA 是当前最大热点：**从 SayCan（LLM 指挥机器人）到 RT-2（动作也可以当"语言"来训练）到 π^0 （流畅连续动作），VLA 让机器人通过看互联网图片就学会了没被直接教过的新技能。
- 5. **世界模型是通往 AGI 的关键拼图：**让机器人在大脑里"做梦"推演各种可能，再选最优方案去执行。LeCun 的 JEPA 系列（V-JEPA-2、PEVA）是这个方向的前沿。
- 6. **数据仍然是最大瓶颈：**机器人数据采集太贵太慢。当前的破解思路有两条——**视频预训练**（先看海量人类视频学常识，再用少数机器人数据微调）和**仿真训练**（在虚拟环境里大规模并行训练后迁移到真实世界）。
- 7. **落地场景集中在结构化环境：**工业制造和仓储物流已经开始部署，但家庭、医院等非结构化场景还差得远。核心瓶颈：泛化能力弱（换个场景就废）、精细操作难（折纸都费劲）、硬件贵。
- 8. **入门不难，关键在于动手：**装一个 Gymnasium 跑 PPO，让虚拟蚂蚁学会走路——一下午就能完成你的"具身智能第一个 demo"。先动手再补理论，比先啃完所有书再动手有效十倍。

附二：术语小词典

按在文中的大致出现顺序排列。每个术语第一次出现时已在正文中用大白话解释，这里做快速查阅用。

术语	英文	一句话解释
具身智能	Embodied AI	给 AI 装上身体，让它通过"看→想→做→看结果"的循环在真实世界中学习
符号 AI	Symbolic AI	传统 AI 流派，认为智能就像计算机一样用抽象符号做逻辑推理
符号落地问题	Symbol Grounding Problem	如果每个词都用别的词来解释，那最终怎么和真实世界连上？——这个问题直接暴露了纯符号 AI 的命门
感知—行动闭环	Perception-Action Loop	"看→想→动→再看→再想→再动"的持续循环，具身智能的基本工作方式
强化学习	Reinforcement Learning (RL)	让机器人通过大量试错来学习——做对了给奖励，做错了扣分，慢慢摸索出最优策略
PPO	Proximal Policy Optimization	强化学习中最常用的算法，让训练过程更稳定，不会"一步走错满盘皆输"
仿真器/仿真环境	Simulator	在计算机里模拟真实物理世界的软件，让机器人在虚拟环境中训练，不用怕摔坏硬件
Sim-to-Real	Simulation to Reality	先在仿真器里学会技能，再迁移到真实机器人上的技术路线
域随机化	Domain Randomization	在仿真训练中随机改变颜色、摩擦力、光照等参数，让模型适应真实世界的多样性
模仿学习	Imitation Learning (IL)	人类演示一遍怎么做，机器人直接照着学——比强化学习从零摸索快得多
行为克隆	Behavioral Cloning (BC)	模仿学习最直接的方式：把"人类操作时摄像头看到啥→机械臂做了啥"记录下来当数据训练

术语	英文	一句话解释
Dagger	Dataset Aggregation	行为克隆的改进版：机器人做错了人类再纠正，把纠正数据也加进训练集，越练越好
世界模型	World Model	在机器人脑子里建立一个对世界的"模拟器"，让它可以在脑海中预演各种行动的结果
自监督	Self-Supervised Learning	模型自己给自己出题（比如预测视频下一帧），不需要人工标注数据就能学习
微调	Fine-Tuning	在一个已经学会通用能力的模型上，用少量特定数据做"最后一跳"，让它学会具体技能
泛化	Generalization	模型把训练中学到的能力应用到从未见过的新场景中的本事
JEPA	Joint-Embedding Predictive Architecture	LeCun 提出的世界模型架构——不预测每个像素，而是预测画面的"抽象含义"（位置、形状等）
多模态	Multimodal	能同时处理多种信息类型（文字+图片+声音+传感器数据……像人一样多种感官并用）
LLM	Large Language Model	大语言模型，如 GPT-4、Claude——通过海量文本训练出来的"文字推理专家"
VLM	Vision-Language Model	视觉语言模型——能同时看懂图片和理解文字
VLA	Vision-Language-Action Model	视觉-语言-动作模型——VLM 的升级版，不仅会看会读，还能直接输出机器人动作指令
Token	—	AI 处理信息的最小单元。文字被切成词/子词，图片被切成小块，每个小块就是一个 token
端到端	End-to-End	输入一头（摄像头画面）直接输出另一头（电机指令），中间不拆成独立模块
自由度	Degree of Freedom (DOF)	机器人可以独立运动的轴的个数。人类手臂从肩到腕有 7 个自由度
正运动学/逆运动学	Forward/Inverse Kinematics	正：已知关节角度求手的位置；逆：已知手要放哪求关节该转多少
灾难性遗忘	Catastrophic Forgetting	学新技能时把旧技能忘光的毛病，就像背了新单词忘了旧单词
流匹配	Flow Matching	一种生成连续、平滑动作序列的技术， π_0 用它让机器人动作不再僵硬
预训练	Pre-training	在大量通用数据上先让模型学"常识"，然后再针对具体任务做微调
Transformer	—	当前 AI 最主流的神经网络结构，几乎所有大模型（GPT、BERT、VLA）都基于它
损失函数	Loss Function	衡量模型预测结果和正确答案之间差距的"尺子"，训练就是不断减小这个差距
反向传播	Backpropagation	神经网络训练的核心算法——算出误差后从后往前逐层调整参数

本文由70asunflower基于 Claude Code 辅助调研撰写。所有参考文献均已在 Semantic Scholar 上交叉核实。
撰写时间：2026 年 6 月。