


李飞飞最新长文：当视频生成、机器人和NVIDIA都自称世界模型，我们需要一个分类法

- 李飞飞最新长文：当视频生成、机器人和NVIDIA都自称世界模型，我们需要一个分类法 - Weixin Official Accounts Platform
- <https://mp.weixin.qq.com/s/WLaF39Dq9caOUeSUSfz1HA>
- 渲染器、模拟器、规划器，以及连接它们的闭环
- 2026-06-04 15:16



李飞飞最新长文：当视频生成、机器人和NVIDIA都自称世界模型，我们需要一个分类法



“世界模型”大概是 2025 年以来 AI 领域里最热也最混乱的概念。Sora 出来的时候，OpenAI 管它叫世界模拟器；Genie 让你在生成的画面里走来走去，也叫世界模型；机器人公司说自己在做世界模型，NVIDIA 说 Omniverse 是世界模型的基础设施，连游戏引擎也被拉进了这个叙事。大家都在用同一个词，但各自说的又完全不是同一件事。

今天，李飞飞在个人 Substack 发表了一篇文章，对这一概念进行了厘清。她首先回到强化学习教科书里那个最经典的图（POMDP 闭环：智能体→动作→状态→观测→智能体），然后指出：现在被叫做“世界模型”的东西，其实是这个闭环的三种不同投影。输出像素（观测）的是渲染器，输出状态的是模拟器，输出动作的是规划器。分类标准非常简洁，就看你输出的是闭环里的哪个部分。



(来源：《麻省理工科技评论》)

她判断，三者之中，渲染器商业化最成熟但有天花板（好看不等于物理正确），规划器最令人兴奋但离真实部署最远（实验室演示和实际可用之间的鸿沟依然巨大），而模拟器是被严重低估的关键枢纽。因为模拟器工作在几何、物理和动力学的层面上，既能向上投射为像素供人类消费，也能向下推导出动作后果供机器人使用。掌握了模拟，就同时拥有了渲染和规划的基础；反过来则不行。

这段话讨论的是机器人、计算机图形学或人工智能领域中的三个核心概念：渲染器、规划器和模拟器。我来帮你补充背景，把术语解释清楚，然后逐句拆解作者的判断。

先理解三个“器”分别是什么

1. 渲染器

- 作用：把三维场景、物体、光照等信息，变成人眼能看到的像素图像（比如游戏画面、电影特效）。
- 追求的目标：好看、真实、有视觉冲击力。

- 商业化最成熟：像游戏引擎（Unity、Unreal）、三维动画软件（Maya、Blender）里的渲染器已经很成熟，被大量应用。

2. 规划器

- 作用：给机器人或智能体**制定行动步骤**。比如“从A点走到B点，途中避开障碍物，先抬起手臂再抓杯子”。
- 追求的目标：**任务完成成功率高、路径合理**。
- “最令人兴奋但离真实部署最远”：实验室里可以做出很酷的规划算法（比如让机器人叠衣服、做饭），但一旦放到真实世界的灰尘、光线变化、意外干扰中，往往失效。这就是“实验室演示和实际可用之间的鸿沟”。

3. 模拟器

- 作用：在电脑里**构建一个虚拟的物理世界**。这个世界遵循物理规律（重力、摩擦力、碰撞、质量、动量等），物体有真实的形状和材质。
- 工作层面：**几何**（形状尺寸）、**物理**（力与运动）、**动力学**（物体如何随力而运动）。
- 举例：你扔一个球，模拟器会计算抛物线、落地反弹；你让机器人推箱子，模拟器会算出箱子滑动还是翻倒。

为什么模拟器是“被严重低估的关键枢纽”？

原文说它既能“**向上投射为像素**”，也能“**向下推导出动作后果**”。

• 向上 → 渲染

模拟器里已经有了物体的几何形状、位置、光照（如果你也设了光源），那么**只需要再加一层渲染算法**，就能生成漂亮的像素画面——这就是游戏或动画的制作流程。

反过来不行：纯渲染器只管画得像，它不关心这个杯子有没有重量、推一下会不会倒。**没有模拟能力，渲染器只是“画皮”**。

• 向下 → 规划

规划器要决定“下一步做什么动作”。但如果不知道动作会产生什么后果（比如推箱子10厘米，箱子会停还是会继续滑），规划就是瞎猜。

模拟器能**精确计算每个动作的物理后果**——这就可以用来训练或验证规划器。比如让机器人在模拟器里试错一百万次，学会“推箱子需要用多大的力”。

反过来不行：规划器只输出“应该做什么动作”，但它本身不会告诉你这个动作在真实物理世界会触发什么结果。

• 所以“**掌握了模拟，就同时拥有了渲染和规划的基础**”

如果你有一个足够好的模拟器：

- 加个渲染模块 → 能输出好看的画面（相当于有了渲染功能）
- 加个搜索/优化模块 → 能在模拟器中模拟动作后果，从而制定规划（相当于有了规划的基础）
但如果你只掌握了渲染器，你没有物理计算能力，无法支持规划；只掌握了规划器，你没有像素生成能力，也无法得到可视化的输出。

最后一句“反过来则不行”的简单例子

- **有模拟器 → 可以轻松加上渲染**：比如机器人仿真软件Gazebo、NVIDIA Isaac Sim，它们本身就能输出摄像头视角的图像。
- **只有渲染器 → 变不成模拟器**：比如你用Photoshop渲染了一张完美的杯子图片，但图片里的杯子没有质量、没有碰撞形状，你无法问“如果让它从桌上掉下去会怎样”。

总结作者的核心观点

- **渲染器**：好看，但可能物理上错误（比如为了画面美而违背重力），而且有天花板。
- **规划器**：最酷，但实验室到现实的鸿沟很大，实际部署难。
- **模拟器**：最被低估。它处在中间枢纽位置——既能生产人类可读的视觉（通过渲染），又能生产机器人可用的物理后果（供规划使用）。**掌握模拟器相当于同时握住了渲染和规划的钥匙**，但反过来不成立。

这篇文章当然也是 World Labs 的产品宣言。他们的 Marble 已经在同时输出高斯泼溅和碰撞网格，试图把渲染器和模拟器统一到一个模型里。文章末尾描绘的终局是一个统一的世界基础模型，能根据下游需求在渲染、模拟和规划之间自由切换。这个愿景是否能实现另说，但作为一个分析框架，渲染器/模拟器/规划器的三分法也许确实有助于穿透当前“世界模型”概念的一部分噪音。

全文译出如下。

“世界是所有发生的事情的总和。”

——维特根斯坦，《逻辑哲学论》，1921

世界不是由文字构成的。

在早先的一篇文章中，我们提出空间智能是 AI 的下一个前沿，而世界模型是通向它的路径。在此，World Labs 团队和我想再深入一层：在如今被冠以“世界模型”之名的众多事物中，哪些功能模块真正构成了这种能力？它们各自的用途又是什么？

空间智能是当前人工智能领域一个非常重要的前沿概念，它试图解决一个根本问题：让AI真正“理解”我们所处的物理世界，而不仅仅是处理信息。这与你之前看到的“模拟器”讨论是直接相关的，是实现具身智能与通用人工智能（AGI）的核心一环。

简单来说，**空间智能就是让机器在三维空间中像人类一样，感知、理解、推理并与环境互动的能力**。它不再是让AI看懂一张“平面的照片”，而是让它看懂一个“立体的世界”。

为了实现空间智能，我们需要为AI构建一个全新的“大脑”，这就是**世界模型（World Model）**。你可以把它理解为AI对现实世界运行规律的内部模拟器。

空间智能：AI从“知道什么”到“理解世界”

当前以ChatGPT为代表的大语言模型（LLM）虽然博学多才，但它们的认知根基其实是“平面的”，就像一个被关在黑屋子里、只能通过文字描述来想象世界的天才。

而空间智能的目标，就是让AI走出这间“黑屋子”，获得对物理世界的“立体”认知能力。著名AI学者李飞飞教授将此定义为AI的下一个前沿。这与我们上一轮讨论的“模拟器”一脉相承——空间智能的实现，正是依赖于强

大的模拟器作为基础。

VS 空间智能 vs. 当前LLM

对比维度	大语言模型 (LLM)	具备空间智能的AI (Spatial AI)
核心认知	语言世界模型：基于海量文本和图像数据学习，擅长处理抽象知识。	物理世界模型：基于对真实三维空间的感知与交互学习，拥有物理常识。
表现局限	难以准确估算距离、判断物体在空间中的摆放，也无法预测推一下桌子上的杯子会发生什么。	能理解物体间的空间关系和物理规律，比如知道杯子放在桌上，推一下会掉到地上。
终极目标	成为出色的“信息顾问”：回答问题、翻译、写代码。	成为可靠的“行动操作员”：开自动驾驶汽车、操作机器人做家务、在灾难现场导航。

世界模型：构建空间智能的核心路径

世界模型，正是为了实现空间智能而构建的AI“新大脑”。你可以将其理解为AI内部的**通用物理模拟器**——它能对物理环境进行生成、交互与预测，这使得AI能够像人类一样，在行动之前先在脑海中进行“预演”和“推理”。

李飞飞教授定义了一个具备空间智能的世界模型，必须拥有以下三种核心能力：

- **生成性**：能生成一个符合几何逻辑和物理规律的3D虚拟世界。例如，给它一张客厅的图片，它能“脑补”出整个房间的3D结构，甚至想象出沙发背后的样子。
- **多模态性**：能理解并输出多种形式的信息。除了看图片、读文字，它更能理解深度图、动作指令等，并能以3D环境等形式输出。
- **交互性**：这是最关键的一环。它能够根据一个“动作”输入，预测世界下一步会发生什么，并与这个虚拟环境进行互动。

正是这种在内部世界模型中进行“如果……会怎样？”的推演能力，使AI能够进行规划、做出决策，从而真正在物理世界中行动起来。

总而言之，空间智能就是让AI从“纸上谈兵”走向“躬行实践”的关键一步。而“世界模型”正是帮助AI建立这种理解、实现这种行动的“大脑”。这完美呼应了你之前提到的，一个强大的“模拟器”是所有复杂智能行为的基础。空间智能与语言智能并非对立，而是互补的。我们正处在迈向通用人工智能的关键转折点上，空间智能将是其中不可或缺的一块拼图。

语言模型赋予了机器对概念、词汇和推理的强大掌控力，但物理世界，无论虚拟还是真实，运行在完全不同的基底之上。**语言模型学习的是文本的统计结构，世界模型学习的是空间与时间的统计结构**：光如何落在一个表面上，一座花园从一个从未被相机捕捉过的角度看起来是什么样子，物体如何响应力并遵循物理定律。

这使得“世界模型”成了当下 AI 领域最重要、同时也最被滥用的术语之一。计算机视觉、机器人学、强化学习和生成式 AI 都声称自己在构建世界模型，但各自指的是截然不同的东西。一个能生成华丽但物理上不可能的火焰的视频模型，一个即兴生成可玩游戏的语言模型，一个忠实模拟燃烧过程的物理引擎，它们都被叫作同一个名字。

古希腊人从来无法就世界由什么构成达成一致，不管是火、水还是不可分割的原子，因为“世界”从来就不是单一的东西。它始终是某个思想家为了推理某种总体性而使用的替代词。AI 继承了同样的问题，而且恰好发生在这个领域最需要精确性的时刻。

分类法背后的闭环

要厘清这种混乱，可以从一张比上述所有技术都更古老的图开始。所有强化学习教材，包括经典的 Sutton 和 Barto，几十年来一直使用同一幅图的变体来描述智能体如何与世界交互。这幅图的正式名称是**部分可观测马尔可夫决策过程 (POMDP)**，而“世界模型”这个术语最初的定义就属于这一传统。

一个智能体（可以是人、机器人或软件系统）执行动作。这些动作改变世界的状态。但智能体永远无法直接看到状态本身，它所接收到的是观测：落在视网膜上的光子、传感器的读数、视频帧中的像素。新的观测引导新的动作，循环往复。

“状态”这个词需要拆开来看，因为在不同领域中它的含义会发生偏移。这里说的不是化学家的状态，不是固态、液态和气态的区别。这里是物理学家和机器人学家的状态：对世界在某一时刻所发生的一切的完整描述，包括每一个物体、每一个位置、每一个速度、每一种属性。状态是世界的底层现实，原则上是完备的，但对于身处其中的任何智能体来说永远不可直接观测。观测是智能体对这一现实的局部视角。动作则是智能体据此做出的回应。

这个闭环（智能体→动作→状态→观测→智能体）正是赋予“世界模型”这个术语其技术含义的结构。这个短语本身更加古老，可以追溯到 Kenneth Craik 在 1943 年的提议，他认为心智通过运行现实的“小比例模型”来进行推理，而到了 1980 年代末和 1990 年代初，这一概念被引入了神经网络领域。这个闭环同样解释了人们今天使用这个术语时的含义。现在被称为世界模型的各种东西，实际上是同一个闭环的不同投影，每一种输出的是闭环中不同的组成部分。

世界模型的三种功能

第一种世界模型是渲染器。渲染器输出的是观测，具体来说面向人眼的像素，而最重要的品质指标是视觉保真度。一个将文本提示转化为电影级航拍镜头的视频模型就是渲染器；像 Google 的 Genie 3 或 World Labs 自己的 RTFM 这样的交互式系统也是渲染器，它们根据用户输入实时生成画面。这类模型不具备对三维结构的显式理解。它生成的是观看者会看到的画面，而不是事物本身的样子。航拍镜头里的建筑从空中看也许完美无瑕，但试着在下面的城市中穿行，它们就会崩塌。

这段话点出了**渲染器型世界模型**的根本缺陷：它只关心“看起来像什么”，而不是“实际上是什么”。所以当你试图“穿行”其中，它就会“崩塌”。

为什么崩塌？因为一个纯粹的渲染器没有**对三维几何和物理规律的显式理解**。让我们一步步拆解：

1. 渲染器做了什么？

- 它的输入：一段文本（比如“从空中俯瞰一座未来城市”）。
- 它的输出：一帧一帧的**像素画面**。
- 它的内部工作原理：通过大量数据学习像素之间的统计规律。它知道“航拍镜头下，建筑的顶部应该是平的，道路像线条一样延伸到远处”。
- 它**没有**构建一个真正的 3D 模型（没有建筑的高度、宽度、位置坐标，没有街道的宽度和材质，没有重力和碰撞）。

2. 什么叫“试着在下面的城市中穿行”？

- 穿行意味着视角从“高空俯视”变成“地面第一人称”。你需要看到建筑的侧面、窗户、门的细节；你需要看到街道的纹理、行人的高度、天空的遮挡关系。
- 更重要的是：穿行要求**整个场景在不同视角下保持几何一致**。比如你一栋楼从东边看是红色，从西边看就不能变成蓝色；你往前走一步，远处的楼应该变大，而背后的楼应该被遮挡。

3. 为什么纯渲染器做不到？

- **没有3D几何**：渲染器只知道“航拍视角下，像素应该这样排列”。它不知道这栋楼的侧面长什么样——因为训练数据里很少从地面视角看过同一栋楼。当你要求它“走到楼下”，它只能凭像素的惯性“猜”出一些画面，但这些画面往往**自相矛盾**：楼可能扭曲、墙壁消失、地面像水一样流动。
- **没有物理一致性**：穿行还需要物理规则，比如你从空中落到地面，应该有速度、重力和碰撞。渲染器完全没有这个概念。它只是生成“下一帧最像什么”，而“最像”不等于“物理上正确”。结果就是：你可能穿过墙体，或者地面突然变成悬崖。
- **没有长期记忆**：渲染器通常是马尔可夫的——只根据当前几帧或动作生成下一帧。穿行10步之后，它早忘了第1步看到的建筑正面长什么样，于是建筑会变形、消失、或突然冒出一个新的。

4. 具体例子：航拍城市为什么会“崩塌”？

- 航拍画面里，建筑看起来是完美的方块，但那是因为**俯视投影**把立体形状压扁了。实际上每栋楼都有高度、墙壁、窗户。但渲染器从未学习过这些侧面的样子——因为它只在鸟瞰照片上训练过。当你试图下降到街道，渲染器发现自己没有关于侧面的任何知识，于是开始“胡乱填补”：可能把楼顶的纹理往下拖，导致墙壁像是融化的蛋糕；可能直接生成一堵马赛克墙；更常见的是，场景变得**不连续**——你向左转头，原本的楼消失了，换成一个完全不同的建筑，就像噩梦里的场景一样。
- 这就是“崩塌”的直观含义：**一旦你需要连续的、多视角的、符合物理的交互，纯视觉生成的系统就会分崩离析，因为它根本没有一个稳定、一致的世界模型在背后支撑。**

5. 真正的世界模型应该是什么？

- 应该像上一轮讨论的**模拟器**：显式地构建几何（点云、网格、神经辐射场）、物理属性（质量、摩擦）、动力学（运动方程）。这样，无论你从空中看还是地面穿行，楼还是那栋楼；你撞到墙，墙会阻挡你。
- 所以那句话的结论是：渲染器是“第一种世界模型”，但它**不完整**。只有加上几何和物理，才能让世界经得起“穿行”考验。

总结：崩塌的原因不是渲染器有bug，而是它的底层原理决定了它**根本没有一个可以“穿行”的世界**——它只有像素。穿行需要的是三维中的连续、一致、有因果的世界，而渲染器给不出。

第二种是模拟器。模拟器输出的是状态：**一种在几何、物理或动力学上忠实的世界表征，人类和计算机程序都能在其上进行计算和交互。**渲染器的契约是纯视觉的，而模拟器的契约是结构性的，它要求几何经得起检验，物理遵循牛顿定律，动力学的行为符合物理法则的预期。模拟器同时服务两类用户。建筑师、设计师、电影人、游戏开发等专业人士需要**超越视觉可信度的准确性**。强化学习智能体、机器人控制器、自动驾驶车辆等计算机程序则把模拟器当作训练场，在其中大规模地与世界交互，测试那些在现实中要么危险、要么昂贵、要么根本不可能执行的场景。

第三种是规划器。规划器输出的是动作。给定一个观测和一个目标，规划器回答的问题是：**智能体下一步该做什么。**在很多意义上，规划器是渲染器的逆过程。渲染器以动作为输入、产出观测，规划器以观测为输入、产出动作，从而闭合了感知-行动回路。视觉-语言-动作模型（VLA）、基于模型的系统，以及新一波的世界动作模型（World Action Models），都是规划器的不同尝试：让系统能够在非结构化的世界中决定机器人应该做什么。

以上三个类别涵盖了当前实际在落地的大部分工作，而它们之间的区分在实践中很有用。但**这三个类别并非从根本上彼此割裂**。它们共享同一套关于世界如何运作的底层知识：几何、物理、动力学。一个能从任意角度渲

染一只杯子的模型，原则上也应该能模拟杯子被推动后会发生什么，并规划一只手去把它拿起来。越来越多最有意思的研究，正在有意地模糊这三者之间的边界。



图 | 三种世界模型（来源：Substack）

为什么模拟是关键枢纽

在三个类别中，模拟器受到的公众关注最少，却是三者中最重要的。这篇文章想纠正这种不对称。

渲染器是目前商业化程度最高的。大量图像或文本转视频产品正在消费和企业市场快速扩张。Google 的 Nano Banana 模型将渲染器级别的图像生成能力送到了可能数以亿计的用户手中。技术是实在的，市场也是实在的。然而渲染器优化的目标是视觉可信度而非物理准确性，这个天花板很重要。它们的输出很漂亮，但你不能用它们来设计一座建筑或训练一个机器人。

规划器是最令人兴奋也最不成熟的，它与快速演进的机器人学习领域密切相关。过去两年里，这个领域产出了不少在视频里看起来令人印象深刻的机器人演示，但我们需要坦诚地面对这些演示究竟展示了什么。几乎所有演示都局限于高度受限的实验室环境，物体种类有限，任务时长很短。没有一个经受过真实世界部署所要求的复杂度、多样性和持续时长的验证。从一段精彩的演示视频到一个能在厨房、仓库或手术室中可靠工作的机器人，中间的鸿沟依然巨大。

尽管如此，商业上的押注规模仍然可观。一波资金充裕的新进入者正在争相推出通用规划系统，而大型基础设施玩家则在将规划能力架设在更广泛的模拟堆栈之上。

模拟是连接两者的桥梁。如果说语言是对世界的抽象，像素是对世界的投影，那么几何、物理和动力学就是世界本身。模拟器必须在这个层面上工作：它是结构性的骨架，视觉表现（供渲染器使用）和动作后果（供规划器使用）都可以从中推导出来。

一个掌握了模拟的模型，能够将它的理解投射为供人类消费的像素，也能投射为供具身智能体使用的动作预测。而一个只掌握了渲染或只掌握了规划的模型，两者都做不到。这里的商业空间极其广阔。仅 NVIDIA 的 Omniverse 一项，其目标市场规模据该公司估计就超过万亿美元，涵盖工厂、仓库、供应链和数字孪生。机器人训练、自动驾驶测试、建筑可视化、工程设计、药物发现，全都依赖于某种形态的模拟。

🤖 物理AI时代：Omniverse的核心定位

Omniverse诞生之初确实是为了解决3D协作问题。但如今它的重心已转变，其核心目标是为“物理AI”（能感知、推理并在物理世界中行动的AI系统）提供开发和测试环境。简单说，它就像一个高度逼真的“虚拟训练场”。

在这个训练场里，你可以：

- **大规模训练**：让机器人在模拟中学习走路、抓取物体，规避风险。
- **安全验证**：在虚拟世界里测试自动驾驶汽车应对各种极端天气和突发路况。
- **优化流程**：在工厂建成前，就在数字孪生中模拟生产流程，提前发现问题。

我们可以通过一个比喻来理解Omniverse的价值：如果为物理AI设计一张名片，它的核心标签会是：

- **名称**：NVIDIA Omniverse
- **定位**：物理AI的操作系统
- **核心价值**：连接并赋能设计、仿真、AI训练与机器人
- **关键客户**：制造业、汽车、机器人、能源、媒体娱乐
- **核心优势**：统一的数据标准 (OpenUSD)、高精度的物理仿真、实时光追渲染、可扩展的模块化架构

⚙️ 底座与引擎：Omniverse是如何构成的？

Omniverse的强大，源于它为开发者准备的一整套核心技术组件。

- **数据互连基石：OpenUSD**：这是Omniverse的“通用语言”。这个由皮克斯最初开发、现由AOUSD联盟维护的框架，让来自不同专业软件的3D数据可以无缝流转和协作。
- **万物物理法则：PhysX®**：作为核心物理仿真库，它为虚拟世界提供符合牛顿定律的模拟，让虚拟物体像在现实中一样运动。同时NVIDIA也与谷歌、迪士尼等联合开发了开源的 **Newton物理引擎**，推动机器人学习。
- **真实视觉呈现：RTX™ 渲染器**：它利用光追技术，将模拟结果、传感器数据等转换成接近真实世界的画面，并支持多GPU加速以获得更高性能。
- **高保真内容标准：SimReady资产**：这是为AI仿真准备的3D模型标准。它定义了资产不仅要有漂亮外观，还必须包含精确的物理属性、传感器响应和功能逻辑，确保仿真结果可迁移至真实世界。
- **新技术扩展：3D Gaussian Splatting**：这是一种先进的3D重建技术，能将现实世界捕捉的点云等数据，高效地转化为高保真3D环境，加速真实场景的数字孪生构建。

🎬 Omniverse在行动：改变世界的真实场景

基于上述能力，Omniverse已成为众多行业龙头实现智能化转型的核心引擎。

- **工业制造与数字孪生**：通过创建工厂的数字孪生体，在生产前进行虚拟规划、验证和优化，大幅缩短部署周期、节约成本。
 - **宝马集团**：使用Omniverse创建了占地超100万平米的虚拟工厂，全球规划人员可实时协作。据估计，这能为其节约30%的工厂规划成本。

- **富士康**：利用Omniverse构建智能工厂数字孪生。借助NVIDIA PhysicsNeMo AI模型，热分析仿真速度比传统方法提升了150倍。
- **SK电讯**：为SK海力士的半导体工厂打造数字孪生，以模拟和优化高度复杂的晶圆厂运营。
- **AI与数据中心基础设施**：通过构建AI工厂的数字孪生，实现计算、供电、冷却等跨系统的协同设计和运营优化。
 - **AI工厂设计**：NVIDIA发布了Omniverse DSX蓝图，利用OpenUSD和SimReady资产来构建和模拟吉瓦级AI工厂，实现了建筑、供电和冷却等与AI基础设施的协同设计。
- **汽车与自动驾驶**：在仿真环境中生成大量虚拟的、带有精确标注的传感器数据，用于训练和验证感知模型，以经济、安全的方式覆盖罕见路况。
- **机器人与物理AI**：为AI驱动机器人提供“入学考试”。
 - **ABB机器人**：将Omniverse集成到其RobotStudio平台后，仿真与现实的吻合度高达**99%**，产品推出周期缩短高达**50%**，调试时间减少高达**80%**。
 - **机器人生态**：NVIDIA的Isaac Sim机器人仿真平台基于Omniverse构建，并与1X、Agility Robotics等领先的人形机器人公司深度合作，用于训练和验证具身智能。
- **媒体与娱乐**：创建虚拟制片环境，将CGI元素实时合成到实拍画面中。NVIDIA还提供了个人免费版，让个人创作者也能用Omniverse进行3D设计协作。

人人可用的工具：Omniverse产品与定价

NVIDIA为不同类型的用户提供了多种产品方案：

版本	主要特性	目标用户
个人免费版	在RTX GPU上，连接主流3D软件，进行实时协作与渲染	个人创作者、艺术家、设计师、学习者
企业版	团队协作、企业级安全、IT部署和专用支持	需要专业协作与IT管理的团队
Omniverse Cloud	通过云提供全套服务，支持云API和DGX Cloud托管服务	希望免除本地硬件管理和扩展难题的企业
Omniverse 库	提供ovrtx(渲染)、ovphysx(物理)、ovstorage(存储)等核心库，以API形式集成进现有应用	软件开发，工业软件公司

总结与展望

总的来说，Omniverse已经从一个3D协作平台，演进为支撑物理AI发展的关键基础设施。它通过OpenUSD统一数据，用PhysX和SimReady资产确保仿真结果可迁移至现实世界，最后以模块化的库服务赋能开发者，构建起一个庞大的工业生态。

展望未来，NVIDIA正通过发展Omniverse库、集成Cosmos世界基础模型、与西门子等CAD/PLM巨头深度合作，推动整个物理AI生态系统的发展，目标是成为定义未来工业智能时代的操作系统。

这个领域最困难的开放性问题也集中在这里。带有显式几何、材质属性和物理标注的三维数据，比渲染器训练所用的互联网视频稀缺了几个数量级。sim-to-real 差距（模拟中的物体行为与真实世界中的行为之间的差异）仍然存在。生成式模拟器在此基础上还引入了新的风险：AI生成的几何体可能看起来正确，但实际上包含自相交或错误比例的问题，导致物理模拟产生荒谬的结果。大规模的多物理模拟（刚体、可变形物体、流体、布料全部同时交互）的计算成本仍然比单一领域的模拟高出几个数量级。

补充:为什么 COMSOL / Ansys CST 这类仿真工具,不适合直接作为世界模型的训练数据来源

核心结论:仿真数据确实可以(也已经在)被当作训练数据,但 COMSOL、Ansys/CST 不是合适的来源。原因如下:

物理领域对不上

COMSOL(多物理场:电磁/结构/传热/流体)、CST(电磁场)解的是窄域工程物理——电路板电磁场、叶片应力、天线 S 参数。世界模型要的是日常常识物理:刚体碰撞、摩擦、物体掉落、倒水、布料褶皱、人走过房间的遮挡。两者分布几乎不重叠。

真正的瓶颈是"建模"本身,而这些工具是消费数据、不是生产数据

稀缺的"带几何+材质+物理标注的 3D 数据",恰恰是这些工具运行前需要你先喂进去的输入(CAD 几何、材料参数、边界条件都要手动设)。所以它们并没有解决稀缺问题,而是预设了这种数据已存在。真正昂贵的环节是大规模地把世界建成高质量 3D 资产,仿真器帮不上忙。

速度和规模差几个数量级

互联网视频近乎零成本提供数十亿帧;一次高精度 FEM/CFD 求解可能要几小时且非实时。无法跑十亿次来凑训练规模。这类工具是为"把一个设计算准"优化,不是为"高吞吐造数据"优化。多物理耦合(刚体+软体+流体+布料同时交互)规模化时又贵几个数量级。

输出格式不对口

它们输出场解(场量、应力张量、S 参数),而世界模型吃的是图像/视频、点云或高斯泼溅、物体轨迹等视觉与几何动态表征,中间还需整套渲染与状态导出管线。

Sim-to-real gap 依然存在

即便"算得准",也只是在其建模假设内准(理想边界、网格离散、线性化)。日常场景里最难的颗粒物、复杂接触、软体,正是仿真最不可靠、最贵的地方。还有风险:生成式几何可能看起来对、却有自相交或尺度错误,产生荒谬物理。

那么谁合适?

机器人/物理仿真器 + 游戏引擎 + 生成式仿真器:

MuJoCo、Isaac Sim、Genesis:实时、可脚本化、做刚体/铰接/接触动力学,配合域随机化批量造场景;

Unreal / Unity / Blender:逼真渲染 + 批量生成带标注合成数据;

生成式仿真器(World Labs 的 Marble):用 NeRF / 高斯泼溅直接生成可交互 3D 世界,试图绕开"逐个人工建模"的瓶颈。

代价:仍要面对 sim-to-real gap 与资产生成质量问题。

一句话总结:仿真数据能当训练数据,但 COMSOL/CST 不行——窄域工程物理、把稀缺资产当输入、又慢又贵、格式也不对;真正的难点不是"算物理",而是"大规模造出带几何、材质、物理标注的多样 3D 世界"。

在 World Labs, Marble 是我们在这个方向上的第一步。它接受多模态输入(文本、图像、视频或空间草图),生成可探索的 3D 环境,同时输出用于视觉探索的高斯泼溅(Gaussian splats)和供物理引擎操作的碰撞网格。但 Marble 只是一段漫长弧线的第一章。随着渲染、模拟和规划之间的界限开始消融,整个领域都在书写这个故事。

这段话描述的是一个**高级世界模型**（或者叫空间智能模型）的能力：输入各种信息，输出一个“双管齐下”的3D世界——既好看，又能让物理引擎操作。下面逐个解释关键词。

1. 多模态输入

含义：模型可以接收多种不同类型的数据作为“提示”，而不是只认文字。

模态就是信息的载体。常见的模态包括：文本（描述）、图像（照片）、视频（动态片段）、空间草图（手绘的俯视图或简单的线条）。

例子：

- 你输入“一个日式庭院”的文字 → 模型生成3D庭院。
 - 你给一张客厅的照片 → 模型生成能走进去的3D客厅。
 - 你在纸上画几个方框表示房间布局 → 扫描后模型把它变成立体的。
-

2. 空间草图

含义：一种表达**空间关系**的手绘示意图，比如俯视的房间布局、建筑的平面草图、几个物体的大致位置。

与普通草图的区别：普通草图强调“画得像”（比如画一只猫），而空间草图强调**几何与位置**：墙在哪、门在哪、物体之间的距离。

用途：让你快速“画出”一个世界的框架，模型据此补全细节和立体结构。类似建筑师用线条勾出户型图，然后AI自动生成3D室内。

3. 可探索的 3D 环境

含义：生成的不是一张静态3D图片，也不是一段固定路线的视频，而是一个你可以**主动在里面移动、变换视角**的虚拟世界。

关键：支持交互。比如用鼠标/VR手柄在环境中“走”、低头看地面、绕过柱子回头看。

与“渲染器输出”的区别：渲染器只给你一个角度的像素（好比电影），而可探索环境像一个游戏场景，你能自由探索。

4. 高斯泼溅（Gaussian splats）

含义：一种**3D场景表示方法**，用来实现超高效率、高质量的新视角渲染。

通俗解释：传统3D建模用“三角形网格”（像铁丝网搭出外形）。而高斯泼溅用无数个微小的**椭球体**（每个都是一个高斯分布）拼出整个场景。每个椭球有颜色、透明度、位置、大小和旋转。渲染时把这些椭球投到2D屏幕上，融合成一张图像。

优势：

- 渲染速度极快（实时）。
- 能保留很细的细节（比如毛发、玻璃反光）。

- 比神经辐射场（NeRF）训练和渲染更快，且不依赖深度学习推理。
- 在这个模型中的角色：**用于**视觉探索**——也就是你“看”这个3D环境时，系统用高斯泼溅来生成漂亮的、连续的、自由视角的画面。

5. 碰撞网格（collision mesh）

含义：一种用于物理引擎的**简化3D几何体**，专门判断“物体与物体是否发生碰撞”。

为什么要简化：原始的高斯泼溅或高精度网格有大量细节（比如一个杯子的把手、花纹），物理引擎如果逐个检查这些细节，计算量太大。碰撞网格用一个或多个简单的形状（盒子、球体、凸多面体）近似表示物体的**硬轮廓**。

例子：

- 一个精美的椅子模型 → 碰撞网格可能是几个扁盒子（坐垫、靠背、四条腿）。
 - 当机器人伸手去推椅子，物理引擎只检查手和这些盒子的碰撞，速度快且稳定。
- 在这个模型中的输出：**模型同时生成“好看的高斯泼溅”（给人眼看）和“物理可用的碰撞网格”（给物理引擎用）。这样你既能在环境中穿行观看，也能让机器人或虚拟物体与场景进行真实的物理交互（比如把杯子碰到地上）。

为什么这两种输出缺一不可？

输出类型	用途	特点
高斯泼溅	实时、高保真的视觉渲染	漂亮、连续、支持自由视角，但不直接支持物理计算
碰撞网格	物理模拟（重力、碰撞、摩擦）	简单、鲁棒、适合引擎，但看起来粗糙

两者配合：

- 你**看到**的是高斯泼溅渲染出的逼真场景。
- 物理引擎**操作**的是背后的碰撞网格。
- 这样虚拟物体既能“看”又能“动”，实现真正的可交互3D环境。

一句话总结

这段话描述了一个能根据文字、图片、视频或手绘草图，自动生成**可自由探索的3D世界**的模型。这个世界同时输出两种表示：**高斯泼溅**（用于快速生成漂亮的视觉画面）和**碰撞网格**（用于让物理引擎计算碰撞和运动）。这是空间智能走向实用的关键技术路径。

边界正在消融，以及接下来会发生什么

当前这个领域最重要的趋势是，**三个类别正在开始融合**。背后的共识是：**渲染一个世界、模拟它、在其中行动**，所需要的知识在很大程度上是相同的。沿用前面的例子，一个真正理解杯子如何放在桌上的模型（它的几何形状、材质属性、对力的响应等等），应该能够从任意角度**渲染**这只杯子，**模拟**杯子被推动后会发生什么，并**规划**一只手去拿起它。三个类别是同一种底层理解的三种投影。

比如，最近已有少量但在增长中的工作来自不同的机器人实验室，它们展示了一种至少在概念上成立的可能性：一个预训练的视频渲染器可以作为联合世界预测和动作预测的骨干网络，让单一模型同时想象“会发生什么”和“该做什么”，从而在渲染器和规划器之间架起桥梁。World Labs 的 Marble 已经能从单一模型同时输出高斯泼溅和碰撞网格，消解了渲染器与模拟器之间的边界。每一个层面都在从被动输出转向交互式系统：渲染器变得可以响应动作条件，模拟器生成的世界变得更加可控和可编辑，规划器开始进行审慎推理而不仅仅是做出反应。

你引用的这段话，揭示了空间智能领域一个正在发生的关键跃迁：**渲染器、规划器、模拟器这三个原本各自独立的模块，正在走向融合**。而融合的桥梁，就是“单一模型同时承担多种角色”。我来逐句帮你拆解背后的逻辑和术语。

1. “一个预训练的视频渲染器可以作为联合世界预测和动作预测的骨干网络”

背景：传统的“渲染器”（比如视频生成模型）只做一件事：根据历史帧生成下一帧（世界预测）。而传统的“规划器”只做另一件事：根据当前状态输出一个动作（动作预测）。两者是分离的。

新思路：用同一个神经网络（骨干网络）同时完成这两个任务。这个网络最初是在大量视频数据上预训练过的，所以它已经学会了“世界如何演变”（比如球会沿抛物线落下）。然后在此基础上，再让它学会“为了达到某个目标，应该输出什么动作”。

类比：就像一个司机，他看多了路上的真实情景（预训练），自然就能预判“前面那辆车会减速”（世界预测），同时也能决定“我也该踩刹车了”（动作预测）。这两个能力用的是同一个大脑，而不是分开的两个系统。

意义：这种方式让渲染器不再是“只会生成好看但无用的像素”，而是开始理解因果和时序，从而为规划服务。

2. “World Labs 的 Marble 已经能从单一模型同时输出高斯泼溅和碰撞网格”

World Labs：由李飞飞联合创立的AI公司，专注于空间智能。

Marble：他们发布的一个模型（具体名称可能内部使用，这里指代他们的技术成果）。

输出：

- **高斯泼溅：**用于高保真实时渲染（给人眼看）。
- **碰撞网格：**用于物理模拟（给物理引擎用）。

传统做法：这两个输出由两套完全独立的系统完成。一个做3D重建+渲染，另一个手工或半自动生成碰撞网格。两者之间没有一致性保证——你看到的精美花瓶，物理上可能是一个立方体盒子，导致机器人抓空气。

Marble的创新：同一个模型，一次前向传播，同时生成两种表示。这意味着视觉外观和物理几何之间**自动对齐**。模型内部必须同时理解“这个物体看起来是什么样”和“它占多大空间、碰撞边界在哪”。

消解了渲染器与模拟器之间的边界：过去，渲染器只管像素，模拟器只管物理，两者是分开的软件模块。现在，一个模型既输出像素级的视觉（通过高斯泼溅），又输出物理级的表示（碰撞网格），所以边界模糊了。你可以说它是“能渲染的模拟器”，或者“懂物理的渲染器”。

3. “每一个层面都在从被动输出转向交互式系统”

这是对三个领域趋势的概括：

模块	过去（被动输出）	现在/未来（交互式）
渲染器	给定输入，生成一段固定视频，用户只能看。	响应动作条件： 用户（或智能体）的动作会影响接下来生成的画面。比如你“向右转头”，渲染器实时生成新的视角。这其实就是可探索3D环境的基础。
模拟器	给定初始条件，按物理规律演化，用户很难干预。	世界变得更加可控和可编辑： 你可以实时修改物体的位置、材质、物理属性，模拟器立即响应。比如“把桌面的杯子移到左边”，场景随之变化。这要求模拟器具备交互式编辑能力。
规划器	基于规则或学习，输出一个动作序列，像反射一样。	进行审慎推理： 规划器开始能够“停下来想一想”，考虑多个步骤的后果，甚至模拟出几种可能的未来再做决定。这需要规划器内部集成或调用世界模型/模拟器进行推演。

底层共同点：所有模块都在从“单向的、只读的”变成“可对话的、可控制的”。这是迈向通用交互式智能体的关键一步。

一句话总结

这段话的核心信息是：空间智能领域的先进工作正在证明，**一个模型可以同时学会“世界如何运行”（世界预测）、“该怎么做”（动作预测）、“视觉上看起来如何”（渲染）以及“物理上如何碰撞”（模拟）**。这四者之间的传统界限正在消失，取而代之的是**统一的、可交互的空间智能模型**。Marble 就是这个方向的一个实例，而更广泛的趋势是：渲染器变得可交互、模拟器变得可编辑、规划器变得有反思能力。

逻辑上的终点是一个统一的世界模型：一个基础模型，能够渲染照片级真实的视图、生成物理上准确的结构、规划动作序列，并根据下游使用者的需求在不同输出模态之间切换。我们仍将面对一系列严峻的挑战。数据格局极不均衡，渲染器坐拥海量互联网视频，而模拟器和规划器则面临3D资产和机器人示范数据的严重匮乏。针对视觉美感的优化可能会牺牲机器人或高保真模拟所需的精度。在单一架构内调和这些张力，是当今世界模型研究的核心开放问题，也是 World Labs 在持续演进 Marble 的过程中致力于解决的。



（来源：Substack）

要填补模拟器和规划器的数据缺口，目前的研究与产业界主要从四个方向取得突破：在真实世界中“采集”，在模拟器中“合成”，用AI自动“生成”，以及综合多种来源的“混合”策略。

以下是主流的数据来源和路线：

真实世界采集：数据质量的“金标准”

真实世界的的数据，特别是通过人类遥控机器人的方式，目前仍然是最高质量的数据来源。

- 遥操作 (Teleoperation)：**操作员通过VR设备或主从控制臂遥控机器人，系统精确记录动作和传感数据。这是OpenVLA等知名模型的训练基础。
- 人类示范 (Human Demonstration)：**鉴于遥操作成本高、规模有限，业界在探索让人类直接示范的更高效方法。
 - 手持式采集器：**斯坦福大学的UMI等工具，让示范者在任意场景演示抓取动作，大幅降低了数据采集门槛。

- **穿戴式设备**：通过低成本外骨骼或数据手套采集人体精细动作，再映射给机器人。RoboPaint就是其中的代表方法。
 - **多模态数据采集**：部分数据采集甚至包含手套关节角度、触觉信号等，使其信息量远超纯视觉视频。
3. **真实世界数据集**：学术界和产业界已开源许多高质量的真实世界数据集。例如，智元机器人开源的AGIBOT WORLD 2026数据集，在真实的商业空间、家居等场景中，记录了包含随机干扰的丰富物理交互。

仿真数据生成：规模化的“廉价工厂”

纯粹靠人工采集数据太慢，仿真就是那个近乎免费、可无限量生产数据的“工厂”。其中最具代表性的当属NVIDIA的Omniverse，它是一个高度逼真的仿真平台，许多前沿工作都基于它展开。

1. **可交互3D资产 (Interactive 3D Assets)**：AI/机器人需要在仿真中理解现实物体的互动属性，因此催生了大量带物理和运动学标注的3D模型数据集。
 - **ArtVIP**：高质量开源数据集，包含由专业建模师制作的数字孪生铰接物体（如门窗、抽屉），确保了视觉和物理双重保真度。
 - **TongSIM-Asset**：由北京通用人工智能研究院发布的数据集，提供**100个**三维场景和**3,000余个**可交互三维物体。
 - **AmaraSpatial-10K**：包含超过**10,000个**带物理属性标注（PBR材质）的合成3D资产。
2. **物理标注数据集 (Physics-Annotated Datasets)**：为了让AI理解物理规律，研究者构建了带物理标注的3D和4D数据集，超越了普通3D模型只关注外观的局限。
 - **PhysXNet**：首个系统性标注的物理基础3D数据集，包含超过**26,000个**物体的物理尺度、材料、运动学等信息。
 - **Artiverse**：高质量铰接物体数据集，包含**5,400个**物体，跨越**88个**类别，标注了关节、部件和物理属性。
 - **PhysInOne**：一个包含**200万个**视频和**153,810个**动态3D场景的超大型数据集。
3. **机器人与导航数据集**：包含机器人操作轨迹、导航路径等特定任务数据。
 - **RoboTwin 2.0**：自动化生成**超过10万条**随机化的双臂操作专家轨迹。
 - **Genie Sim 3.0 Dataset**：智元机器人开源平台，包含**上万小时**的仿真数据集，覆盖**200+**项任务。

AI生成3D资产：解决匮乏的“新引擎”

除了人工和物理模拟，AI也被用来直接生成训练所需的3D资产。例如，智元机器人的Genie Sim 3.0平台，已经支持通过文本或单张图片，在几分钟内生成高保真、可交互的三维场景。

混合生成：虚实结合的“最优解”

数据来源并非孤立，多种路线的混合使用和交叉验证正在成为主流。

1. **“真实-仿真-真实”(Real-Sim-Real)**：这是另一种创新的混合思路，通过建立高精度数据采集室，捕捉人类的多模态演示，然后将动作重定位到仿真机器人上，渲染出大量带完美标注的数据，最终迁移回真实

机器人执行。

2. **AI增强的混合生成**：这种方式混合使用多种技术和数据源来生成全新的、更丰富的数据。例如，智元机器人的**AGIBOT WORLD 2026**数据集不仅包含真机数据，还利用数字孪生技术在仿真中1:1重建了真实场景，并同步开源仿真数据。
3. **世界模型与仿真结合**：更前沿的探索是利用大型“世界模型”来辅助数据生成。NVIDIA的**Cosmos世界模型**本身在大量真实影像上训练出“物理直觉”，能为仿真器提供更逼真的模拟，从而产生的数据更贴近现实。

但大方向已经很清楚。从 1980 年代末至今，**这个领域押的始终是同一个赌注：只要世界模型足够丰富，智能体看见世界、构建世界、在其中行动所需的东西就全在里面了**。这个赌注如今正在驱动一整代人的研究。而真正给它加上砝码的，是已经在发生的融合：渲染、模拟、规划三条线，每条都已经各自撑起价值数十亿美元的产业，它们起初是独立的研究方向，现在开始汇到一起。当边界消失，三者合流将重新定义一件更大的事：机器智能与它所栖居的物理世界之间的关系，也就是空间智能的长远走向。

语言给了机器一种谈论这个世界的方式。世界模型，则是机器最终得以理解、想象、推理并与之交互的途径。

参考资料：

1. <https://drfeifei.substack.com/p/a-functional-taxonomy-of-world-models>

注：首图由 AI 辅助生成