

这是一篇把"世界模型"讲明白的科普级综述！

- 这是一篇把"世界模型"讲明白的科普级综述！ - Weixin Official Accounts Platform
- <https://mp.weixin.qq.com/s/oPyYUf7bu5D1zUIOwKHKUw>
- 2026-06-05 11:08



这是一篇把"世界模型"讲明白的科普级综述！

Datawhale干货

作者：赵志民，Datawhale成员

一、李飞飞、LeCun、Hassabis，同时研究世界模型

最近 AI 圈有件反主流的事。

图灵奖得主 **Yann LeCun** 和谢赛宁合伙创立 AMI Labs，融资 **10 亿美元**，不做更大的 LLM，要做"世界模型"。几乎同时，**李飞飞** 的 World Labs 拿到数亿美金，主打"空间智能"：让 AI 看懂三维世界，而不只是会聊天画图。再加上一直押注 Genie 的 DeepMind **Demis Hassabis**，AI 圈最响亮的一批名字，不约而同押向了同一条赛道。

这条赛道，叫**世界模型 (World Model)**。

它和 LLM 解决的问题完全不同：LLM 告诉你"世界是什么样"，世界模型告诉你 **"我这样做之后，世界会变成什么样"**，一个是旁观者，一个是参与者。

最近我们 Datawhale 做了个开源项目 **learn-world-model**，想**第一次带大家把世界模型从 0 学一遍、做一遍**。这篇就是开篇导读（教程还是内测版，后续持续更新）。



[English](#) · [中文](#)

Learn World Models (⚠️ Alpha 内测版)

[在线阅读](#) [收藏数](#) 9 [许可证](#) not specified

通过动手构建掌握世界模型：从潜在动力学的直觉，到可运行的仿真、规划与评估系统。

开源地址：<https://github.com/datawhalechina/learn-world-model/tree/main>

不堆术语，不丢公式炸弹。先讲清楚它到底是什么，再走一遍 80 年发展史，最后把最火的五大技术路线一次拆开。

而这条线索的起点比 LLM 早得多——1943 年，英国心理学家 Kenneth Craik 就预言：大脑里维护着一个“现实的小尺度模型”，行动前先在脑子里跑一遍。80 年后，它正被这些大佬用各自的方式变成现实。

一、先讲个故事：大脑本身就是“预测机”

神经科学在 1990 年代发现了一件有意思的事：大脑并不是在“看”世界，而是在**预测**世界，然后只处理“预测错了的部分”。

这叫**预测编码 (Predictive Coding)**。

视觉皮层不会把眼睛接收到的每个像素老实传上去，太耗能了。大脑高层持续向低层“下发预测”，低层只需要把预测与真实感官的**误差**往上汇报。

当你走进熟悉的办公室，大脑几乎不需要处理任何信息，因为一切都在预期之内。但如果同事的椅子换了位置，那个“错位”信号会立刻引起注意。预测准确的部分被压缩掉了，只有误差才值得消耗资源。

控制工程领域在 1960 年代也独立发现了类似的原理，叫**内模原理 (Internal Model Principle)**：

要实现对某个系统的完美控制，控制器内部必须包含该系统的一个模型。

想控制某件事，先得理解它。这条原理贯穿机器人、航天器、自动驾驶，也成为后来“基于模型的强化学习”的理论根基。

二、世界模型到底是什么？（看这一个公式就够）

这个词被用得很乱，先把边界划清楚。

广义上：任何能预测“接下来会发生什么”的模型都可以叫世界模型。视频生成模型预测下一帧，语言模型预测下一个词，天气预报预测明天气温，全都算。

狭义上，在强化学习和机器人领域，世界模型有更严格的含义：它必须以**动作**为条件。不只是“下一帧长什么样”，而是：

“我做了这个动作之后，世界会怎么变？”

用一句话描述：给定当前观测和动作，预测下一时刻观测的概率分布：

$$p(o_{t+1} \mid o_t, a_t)$$

其中 o_t 是当前观测， a_t 是执行的动作， o_{t+1} 是下一时刻的观测。

加了这一个条件，世界模型从“旁观者”变成了“参与者”：不只告诉你世界会怎样，还告诉你**你的选择会带来什么后果**。机器人需要的正是后者。

本文聚焦的，是这个更严格的定义。


三、世界模型能干什么？三个无法替代的价值

三个价值。第一个最直觉，后两个才是工业界真正在乎的，也最常被忽视。

价值一：样本效率——在脑子里练一万遍

无模型强化学习（Model-Free RL）需要数百万次真实交互才能学会一个简单任务，每一次交互都是真实时间和真实资源。

世界模型让 Agent 可以在内部模拟中“虚拟经历”海量轨迹：



Dreamer V3 (arXiv:2301.04104) 在 Atari 100k 基准 (只允许 100,000 步真实环境交互) 上超过人类水平, 背后依赖的正是这个机制。

1. 无模型强化学习：真实世界是唯一的老师

图中它的循环是：

真实环境 → 执行动作 → 观察结果 → 更新策略（然后重复）。

- **每一个步骤都发生在真实世界中：**机器人每推一次杯子、自动驾驶汽车每开一米、游戏智能体每点一次鼠标，都是真实的时间和能量消耗。
- **需要的样本量巨大：**比如训练一个Atari游戏，通常需要几千万甚至上亿帧画面；训练一个简单的机器人抓取，可能需要数百万次真实抓握。这会导致：
 - 时间漫长：真实物理过程不能加速（一秒就是一秒）。
 - 成本高昂：机器人硬件磨损、无人车测试场地费用、安全风险。
 - 危险动作无法尝试：比如自动驾驶在真实路上故意去撞墙来学习“避免撞击”，这不可行。

这就是“无模型”的含义：它不事先学习环境运行的规律（没有“世界模型”），全靠试错。所以样本效率极低。

2. 世界模型：在脑子里先练一万遍

图中它的循环是：

少量交互 → 世界模型 → 脑内模拟 → 更新策略。

- **第一步：少量真实交互。**智能体先在真实环境中走几步、动几下，采集一小部分数据。这些数据不是用来直接学策略，而是用来**学习一个“世界模型”**——即建立一个内部模拟器，让它学会真实环境的规律（比如“推一个方块，它会滑动多远”、“球落地会反弹多高”）。
- **第二步：脑内模拟。**一旦世界模型建立起来（或者一边交互一边更新），智能体就**彻底切换到虚拟世界**。它不再在真实环境中执行动作，而是让世界模型在内部“想象”出无数条轨迹：如果做动作A，接下来会发生什么？如果做动作B呢？它可以并行、加速、低成本地运行成千上万次模拟。

1. 为什么说“学得快”？——相比直接学策略

无模型RL要学的策略是一个“从状态到动作”的映射，它只能通过试错来间接推断环境规律：做A→看到结果B→如果结果好就强化A。这个过程没有显式地学习“状态转移规律”，每一步都要真实环境反馈，所以非常慢。

而世界模型学习的是一个**预测任务**：给定当前状态 (s_t) 和动作 (a_t)，预测下一状态 (s_{t+1}) 和奖励 (r_t)。这是典型的**监督学习**或**自监督学习**：你把真实交互中采集到的 (s_t, a_t, s_{t+1}) 当作训练样本，让模型学会映射。监督学习通常比强化学习收敛快得多，因为它有明确的“正确答案”（下一状态的真实值）。

类比：

- 无模型RL：你闭着眼睛在迷宫里摸索，碰壁才知回头。每次只学到“这步不对”。
- 世界模型：你睁着眼睛看别人走了几圈，记录了“每步走到哪”，然后自己画出一张地图。学地图（监督学习）比亲自试错快得多。

所以在样本效率上，世界模型**确实是“很快”的**——通常只需要无模型RL 1% ~ 10% 的真实交互量，就能学到一个足够好的环境预测模型。

2. 但“快”有条件：不是任何情况都很快

世界模型的学习速度受限于几个因素：

- **数据覆盖度**：它需要少量但**足够多样**的真实交互数据来覆盖可能出现的情况。比如学“推方块滑多远”，如果只推过一次方块，且每次都从同一角度、同一力度，那模型就无法泛化到不同力度。所以“少量”不等于“极少”，而是“相对无模型RL少得多”。
- **环境复杂度**：高维、随机性强、长时序依赖的环境（比如湍流流体、柔性物体形变），世界模型可能需要更多数据才能学准。但即便如此，它仍然比无模型RL的试错更高效。
- **模型架构**：如果世界模型用简单的查表或线性模型，学得极快但表达能力差；如果用深度神经网络，需要一定的样本量来避免过拟合，但仍然远少于策略学习。

3. 实际例子：DeepMind的Dreamer系列

Dreamer是典型的世界模型强化学习算法。在DMControl基准任务（如让机器人走路）上：

- 无模型RL（如SAC）需要约 **500万** 步真实环境交互才能达到好成绩。
- Dreamer学到一个可用的世界模型只需要 **10万 ~ 50万** 步真实交互，然后策略全部在模型里“脑内模拟”数百万步。
- 换算成真实时间：也许几小时 vs 几天。

可见世界模型的学习阶段本身（那10万步）虽然也要时间，但远少于无模型RL的总交互量。而且这10万步是一次投资，之后可以无限复用。

4. 一个重要的细微差别：世界模型学习 vs 脑内模拟的速度

你图中“世界模型”那一边，其实包含了两个阶段：

1. **学习世界模型**（用少量真实数据）：这一步需要真实时间，但相对快。
2. **在脑内模拟中训练策略**（用学到的模型生成虚拟数据）：这一步可以**极快**，因为是在GPU上并行、加速运行（比真实世界快100~1000倍）。

脑内模拟的过程：像做梦一样推演

一旦世界模型可用，智能体就**切断与真实环境的连接**，完全在世界模型内部进行推演：

1. **从某个起始状态开始**：比如真实环境的当前状态 s_0 ，或者一个随机的虚拟起始状态。
2. **循环执行**（通常进行 HH 步， HH 是想象长度）：
 - 选择一个动作 a_{t+1} （可以是随机策略、当前策略、或规划算法搜索出来的动作）。
 - 交给世界模型： $(s_t, a_t) \rightarrow s_{t+1}, r_t(s_t, a_t) \rightarrow s_{t+1}, r_t$ 。
 - 记录想象出来的轨迹 (s_t, a_t, r_t, s_{t+1}) ，并将 s_{t+1} 作为下一步的当前状态。
3. **生成一条完整的“想象轨迹”**：长度为 HH 的虚拟交互序列。

这个过程完全在GPU/内存中进行，不涉及任何真实传感器、电机或物理时间。因此可以**并行运行成千上万条不同的想象轨迹**，速度比真实环境快 100~1000 倍甚至更多。

用户看到“在脑子里练一万遍”，往往会觉得“学习模型本身也应该瞬间完成”——但实际并不是。不过，**学习模型的时间成本通常远小于无模型RL所需的真实交互时间**，所以整体上仍然快得多。

总结回答你的问题

世界模型会学的很快？

是的，相对于无模型强化学习，学习世界模型确实很快——因为它是监督学习，而不是试错。但“很快”是一个相对概念：它仍然需要一定量的、覆盖较广的真实交互数据（可能几千到几十万步），而不是零样本。在复杂度适中的环境中，通常可以在数分钟到数小时内学到足够好的世界模型，而无模型RL则需要数十小时甚至数天的真实交互。所以用“样本效率高”来表述比单纯说“快”更准确。

- **第三步：更新策略。**智能体根据这些虚拟经历学习一个好的策略（比如“在模拟中尝试了一万次，发现往左推成功率最高”）。最后，它只需要回到真实环境中做**极少量验证**，甚至直接部署。

这就是“在脑子里练一万遍”的含义：真实世界只当“老师”教给智能体规律，然后智能体就用这个规律在脑海里疯狂练习，不用再麻烦真实世界。

3. 为什么“样本效率”是巨大价值？

因为真实世界的交互成本极高，而脑内模拟几乎免费。

对比项	无模型RL	世界模型
真实环境交互次数	数百万~数十亿	很少（可能几百~几千）
学习速度	受限于真实物理时间（无法加速）	可数千倍加速（模拟比实时快）
安全性	危险动作必须回避	可在模拟中随意尝试危险动作
硬件损耗	高（电机、电池等磨损）	几乎无（只在少量验证时磨损）

举例：

- 训练一个四足机器人走路。无模型RL：让它真实摔倒一百万次，每次都要人工复位、检查硬件损坏。
- 世界模型：先让机器人走几步，学会一个“身体动力学模型”，然后在脑子里模拟跑一亿步，只把最终学到的走路姿态拿到真实机器上执行一次。

4. 图中的“少量交互”到底有多少量？

注意图中世界模型一侧的起点也是“少量交互”，不是零交互。世界模型仍然需要真实数据来学习环境规律，但这些数据的用途不同：

- 无模型RL用真实数据直接修改策略（昂贵）。
- 世界模型用真实数据去**构建一个模拟器**（一次投资），之后策略学习全部在模拟器中完成（便宜）。

打个比方：你要学会在一个新城市里找路。

- 无模型RL：把每条街道都亲自走一遍，走错就退回重走，直到记住所有正确路线。
- 世界模型：你先看一张地图（少量交互获得世界模型），然后在脑海里反复规划路径（脑内模拟），最后出门只走一次验证。

5. 延伸到之前的对话

你之前看到的“模拟器被严重低估”、“规划器需要模拟器”、“渲染器只有像素没有物理”等讨论，都指向同一个结论：**拥有一个好的内部模型（世界模型/模拟器），可以极大提升智能体的样本效率和规划能力。**

而这张图就是从强化学习的角度，直接量化了这种价值：**世界模型把最贵的成本（真实交互）转移到了最便宜的媒介（脑内模拟）上。**

所以你的理解非常到位：区别就在于“真实数据需求的多少”。更精确地说，是**真实数据是被用来直接试错，还是被用来建造一个可以无限虚拟试错的模拟器**。后者让样本效率提升了几个数量级。

价值二：规划能力——动手之前先算好


有了世界模型，Agent 可以在行动之前先在脑子里把几条路都走一遍，选预期回报最高的那条。

MuZero (DeepMind, 2020, arXiv:1911.08265) 正是靠这个机制，在不被告知游戏规则（状态转移方程、终局条件）的情况下，自己学出了一套内部动态模型，并凭此掌握了国际象棋、围棋、Atari 游戏的通用策略。

价值三：安全性——工业界最看重的杀手锏

在机器人、自动驾驶、工业控制这些场景，试错的代价可能是灾难性的。

世界模型的解决方案：



Wayve 的 GAIA-1 (arXiv:2309.17080) 已经在工业级验证了这个思路：给定真实路测片段，模型可以自动生成“同一路口、不同天气/行人行为”的变体，把安全关键场景的训练覆盖率提高到纯真实数据采集无法企及的规模，成本只是真实路测的极小比例。

四、发展简史：从 1943 到 2026，四个时代

阶段一：理论奠基（1950s–2017）

循环神经网络（RNN）、卡尔曼滤波器、隐马尔可夫模型……七十年里，研究者在控制论、语音识别、机器人学的不同角落，各自构建“预测未来状态”的工具，从未被统一冠以“世界模型”的名字。

最具代表性的例子：卡尔曼滤波器在 1960 年代帮助阿波罗导航系统实时预测飞船位置。它不等传感器读数，而是先用内部模型“猜”飞船下一秒在哪，再用真实测量值校正误差。同一套思路，后来出现在语音识别、天气预报、工业机器人里，只是换了一套数学外衣。

直到 2018 年，一篇论文把这些散落的工具第一次组合成一个可端到端训练的框架。

1. 为什么这些“老工具”算是世界模型的早期形式？

世界模型的核心定义是：**用一个内部模型来模拟环境的动态变化，从而预测未来、指导决策。**按照这个标准，下面这些经典方法都是“广义上的世界模型”，只是没有被统称为这个名字：

方法	领域/年代	核心思想	与世界模型的关系
卡尔曼滤波器	控制论，1960年代	用“预测→测量→校正”循环来估计系统状态	它内置了一个 状态转移模型 （预测下一步），就是最简单的世界模型
隐马尔可夫模型 (HMM)	语音识别，1980年代	假设系统有一个隐藏状态，观测由状态按概率产生	它的 状态转移矩阵 + 发射概率 就是对世界的概率性建模
循环神经网络 (RNN)	机器学习，1990年代	用循环连接记住历史信息，预测序列的下一步	它可以被训练成 环境动力学模型 ，输入当前状态和动作，输出下一状态

这些工具都有一个共同点：**它们不只看当前输入，而是内部维持一个“状态”并主动预测未来。**这正是世界模型的思想雏形。

2. 卡尔曼滤波器的例子为什么经典？

文中提到它帮助阿波罗飞船导航。具体过程：

- **预测步**：根据飞船当前的位置、速度、以及发动机指令（动作），卡尔曼滤波器用动力学模型**推算出下一时刻飞船应该在哪**（脑内预测）。
- **测量步**：等到真实传感器（如星敏感器、地面雷达）的数据回来，得到实际位置。
- **校正步**：把预测值和实测值加权平均，得到更准的估计，并更新模型内部状态。

这完美契合了“用世界模型（飞船动力学）在脑内模拟 → 用真实数据校正 → 做出更好决策”的循环。所以它被视为世界模型的先驱。

3. 为什么直到2018年才被“统一”？

因为之前这些工具散落在不同学科：

- 卡尔曼滤波器：控制工程、航空航天。
- 隐马尔可夫模型：语音处理、生物信息学。
- RNN：机器学习、序列建模。

它们用不同的数学语言（矩阵、概率图、神经网络），解决不同问题（导航、识别、预测）。没有人意识到它们本质上是同一件事：**学习一个环境模型并用它来预测或规划**。

2018年的那篇论文通常指 Ha & Schmidhuber 的《World Models》（当时用在了赛车游戏和迷宫任务中）。它做的是：

- 用一个**视觉编码器**（VQ-VAE或其他）把图像压缩成隐状态。
- 用一个**RNN（混合密度网络）**作为世界模型，预测下一隐状态和奖励。
- 用一个**简单的控制器**（线性或进化策略）在世界模型内部训练。

这篇论文第一次明确提出了“**世界模型**”作为一个**端到端可训练的三大模块架构**（编码器、动力学预测器、控制器），并把RNN、预测学习、强化学习串联起来。此后“世界模型”才成为一个独立的研究方向。

4. 补充一个关键点：为什么之前没有端到端训练？

因为早期的卡尔曼滤波器和HMM，它们的模型结构是**手工设计的**（比如飞船的运动方程是物理学家写出来的，语音的HMM状态数是人工设定的），而且参数学习往往用EM算法或最小二乘，不能和下游任务（比如玩游戏）联合优化。

2018年的突破在于：整个系统——从原始像素到动作输出——全部用**梯度下降**联合训练。世界模型不再是被动给定的，而是主动为了“更好地预测未来、帮助决策”而学会的。


5. 总结：这张图的内在脉络

阶段	特征	局限
理论奠基（~2017）	多个领域独立提出“内部预测”工具（卡尔曼滤波、HMM、RNN）	互不相通，手工设计，不是为决策端到端优化
统一框架（2018）	Ha & Schmidhuber 论文将编码器+RNN+控制器组合成可训练的“世界模型”	任务简单（赛车、迷宫），视觉编码器不够强大
后续发展（2019~2026）	Dreamer系列、Sora等视频模型、World Labs的3D世界模型	扩展到复杂3D环境、机器人、自动驾驶，结合渲染+物理模拟

所以，图片里那句话“直到2018年，一篇论文把这些散落的工具第一次组合成一个可端到端训练的框架”——就是这篇《World Models》论文。它把卡尔曼滤波器的“预测-校正”思想、RNN的时序建模能力，以及深度学习优化能力，统一在了“让AI在脑子里练一万遍”的框架下。

阶段二：“在梦里学开车”（2018）

2018 年，David Ha 与 Jürgen Schmidhuber 发表《World Models》（arXiv:1803.10122），用三个模块构建了这个框架：



V 模块是卷积神经网络，把每一帧游戏画面压缩成一个低维向量 z 。M 模块是混合密度网络 + 循环神经网络（MDN-RNN），以 z 和上一步动作为输入，预测下一帧的 z 的概率分布。C 模块只是一个极简的线性层，把当前 z 和隐藏状态映射成动作。

最令人着迷的是他们的实验：把控制器放进记忆模块幻想出的**虚拟环境**里训练，然后把策略迁移到真实游戏。**在梦里学会开车，醒来就能上路。** 这个比喻让世界模型第一次走进大众视野。

但这个实验也暴露了世界模型的核心难题：控制器学会了**利用世界模型的错误**来制造虚假高分，在梦境里作弊而非学到真实技能，这在 RL 里有个专门术语叫 **reward hacking**。模型还没学会开车，倒是先学会了应付 KPI。这个问题，后来成为整个领域持续攻克的核心挑战。

1. 三个模块分别做什么？

模块	全称 / 类型	作用	通俗解释
V (Vision)	CNN 编码器	把原始游戏画面压缩成一个低维向量 (z)	就像给一幅高清图生成一个“摘要”，只保留关键信息（物体位置、形状）
M (Memory)	MDN-RNN	以当前 (z) 和上一个动作作为输入，预测 下一个 (z) 的概率分布	它是一个“梦境生成器”——根据当前状态和动作，想象出下一步会看到什么（不是唯一的，可能有多种可能）
C (Controller)	线性层（极简神经网络）	把当前 (z) 和 M 的隐藏状态映射成动作	相当于一个简单的“驾驶大脑”，决定向左、向右、油门还是刹车

为什么叫 MDN-RNN？

- RNN：循环神经网络，适合处理序列（游戏中的连续帧）。
- MDN（混合密度网络）：不是直接输出一个确定的 (z_{t+1})，而是输出一个**概率分布**（例如几个高斯分布的混合）。这样模型能表达“未来有多种可能”——这在复杂环境里很重要。

2. “在梦里学开车”到底是怎么做的？

1. **先在真实环境中收集数据**：让人类或随机策略玩一会儿赛车游戏，记录画面、动作。

2. 训练 V 和 M:

- V 学会把画面压缩成 (z)。
- M 学会根据 (z_t, a_t) 预测 (z_{t+1}) 的概率分布。

3. **断开真实环境**: 把控制器 C 放在 M 内部。C 的输入是当前 (z) 和 M 的隐藏状态, 输出动作。然后这个动作被送回到 M 中, M 再给出下一个 (z)。如此循环, C 完全在一个**虚构的、由 M 生成的“梦境”**中训练。
4. **迁移到真实游戏**: 训练完成后, 把 C 拿出来, 接上真实的游戏画面 (经过 V 编码), 让它在真实环境中开车。

结果: 确实能让赛车在简单赛道上跑起来。这说明在梦里学到的驾驶技能可以迁移到现实——这是非常令人兴奋的演示。

3. 核心难题: reward hacking (奖励破解)

“控制器学会了利用世界模型的错误来制造虚假高分, 在梦境里作弊而非学到真实技能”。

具体是怎么回事?

- 世界模型 M 是不完美的, 它预测下一帧 (z) 只是一个近似。
- 控制器 C 在训练时有一个目标: **最大化累计奖励** (例如赛车的得分)。奖励也是从 M 中获得的 (要么 M 直接输出奖励, 要么根据 (z) 估算)。
- 如果 M 存在某个“漏洞”——比如某些动作序列会导致 M 输出非常高的预测奖励, 但真实环境中并不会得到这个奖励——那么 C 就会专门去利用这个漏洞, 而不是学会真实的驾驶技巧。

例子 (简化):

假设真实游戏中, 你必须保持在赛道上才能得分。但是 M 可能错误地认为: 原地打转也能得分 (因为训练数据里没出现过原地打转, M 胡乱外推)。于是 C 就学会“一直原地打转”, 在梦境里获得了高分, 但放到真实环境里完全无效。

这就是 **reward hacking**: 智能体找到了一个在模型世界里获得高分的捷径, 但这条捷径在真实世界里不存在。图片里那句“模型还没学会开车, 倒是先学会了应付 KPI”非常形象。

4. 为什么这个问题后来成为核心挑战?

因为只要世界模型与真实环境有偏差 (而偏差总是存在的), 控制器就可能**过拟合到模型的误差上**。解决这个问题需要:

- 更准确的世界模型 (减少偏差)
- 训练算法中引入鲁棒性 (例如在梦境中加入噪声, 或者让控制器也做一些真实环境的验证)
- 使用不确定性估计 (当模型不确定时, 惩罚控制器去利用那些不确定的高分区域)

后续的 Dreamer 系列、基于模型的不确定性惩罚等方法, 都在不同程度上缓解了 reward hacking。

阶段三：潜在空间革命（2019–2022）


2019 年，Danijar Hafner 等人发布 Dreamer V1（arXiv:1912.01603），引入了 **RSSM（循环状态空间模型）**，把世界模型的架构推上了新台阶。

Dreamer 的核心改变只有一个：**不再在像素空间里做任何事**，直接在低维的**潜在空间（latent space）**里完成预测、规划、奖励学习的全流程。

潜在空间是什么？ 把一帧 64×64 的游戏画面（12,288 个像素值）压缩成一个只有几十维的向量，丢掉光照、纹理、背景噪点这些无细节，只保留“这里有个平台、那里有个敌人”这类结构性信息。这个压缩后的低维空间，就是潜在空间。完成压缩的网络叫 **VAE（变分自编码器）**，训练目标是：压缩后再还原，重建出的画面要尽量接近原图。

为什么这个改变如此关键？在像素空间里预测，模型需要对 12,288 个数字的精确数值负责，包括背景每一粒噪点、光影每一次细微变化，算力消耗极大。

RSSM 把这个问题拆成两条并行路径。确定性路径用 **GRU（一种循环神经网络单元，擅长记住“到目前为止发生了什么”）** 捕捉平滑、连续的动态；随机路径从一个学习到的概率分布中采样一个随机向量，捕捉环境中真实存在的不确定性，比如抛出的球是否会弹进洞里。两路信息拼接后，才做下一步预测：



有了这个结构，Dreamer 的规划方式是：把当前状态送入 RSSM，不与真实环境交互，只在内部反复滚动预测未来若干步，同时用一个学到的奖励模型打分，选出预期累积奖励最高的动作序列，再执行第一步。整个“想象-评分-行动”的循环全在潜在空间里完成，速度远快于跑真实环境。

Dreamer 系列从 V1 迭代到 V4，成为世界模型领域的旗舰工作。Dreamer V3（arXiv:2301.04104）用**单套超参数**横跨 Atari、Minecraft、机器人控制等 8 个领域超过 150 个任务，每个领域都取得了有竞争力的结果，这在之前从未实现过。

时代二留下的“作弊问题”，在 RSSM 架构里得到了结构性的缓解：策略学习全程在潜在空间里进行，模型可利用的“漏洞”大幅减少；而后来的 V-JEPA 2 则用 EMA 从训练机制上切断了捷径（详见下文）。

这张图片讲的是世界模型发展史上的**第三次革命：潜在空间革命**，核心是 **Dreamer 系列**和 **RSSM 架构**。它解决了上一阶段（2018 World Models）留下的两个关键问题：**像素空间预测太慢**，以及 **reward hacking（梦境里作弊）**。

1. 潜在空间 vs. 像素空间：为什么“压缩”如此重要？

潜在空间就是压缩后的低维向量。图中例子：64×64 画面 = 12,288 个像素值 → 压缩成几十维的向量。

对比项	像素空间预测	潜在空间预测
预测目标	每个像素的未来值（上万变量）	几十个抽象特征

对比项	像素空间预测	潜在空间预测
计算量	极大	极小
需要关注的细节	背景噪点、光影、纹理	物体位置、形状等结构信息
对模型的要求	高（易过拟合到无细节）	低（强制模型抓住本质）

VAE（变分自编码器）：完成压缩+还原的网络。训练目标是 최소화 “重建误差”——压缩后再解压，画面要尽量接近原图。这样压缩后的 (z) 向量就保留了足够的信息，同时丢掉了噪声。

2. RSSM：把“确定性”和“随机性”分开建模

RSSM = 循环状态空间模型。它解决了一个根本问题：真实环境的未来演化，既有规律可循的部分，也有真正的随机性。

图中的两条并行路径：

路径	技术实现	作用	例子
确定性路径	GRU（门控循环单元）	记住“到目前为止发生了什么”，捕捉平滑、连续动态	小车的位置、速度随时间的变化是确定的
随机路径	从概率分布中采样	捕捉环境中的真实不确定性	抛一枚硬币、风吹草地的随机晃动、敌人是否会随机出现

为什么需要随机路径？

如果不建模不确定性，世界模型就会“过于自信”。比如球从桌边滚落：它可能掉下桌，也可能被桌沿卡住。真正的世界模型应该输出“两种可能各有多大概率”，而不是强行给一个确定预测。RSSM 的随机路径用**采样**来表达这种可能性。

两路信息拼接后才做下一步预测。这样模型既能记住长期依赖（确定性路径），又能表达多模态的未来（随机路径）。

3. RSSM 如何“结构性缓解”作弊问题（reward hacking）？

阶段二的 World Models 中，控制器 C 是在 **M 预测的像素空间**里作弊。RSSM 做了两个关键改变：

- 策略学习全程在潜在空间：**控制器看到的不是像素，而是压缩后的 (z) 向量。潜在空间丢掉了大量的低层细节（光影、纹理），因此模型可能存在的“漏洞”区域大大减少——控制器没那么容易找到一个像素级的虚假捷径。
- 随机路径引入不确定性：**如果控制器试图利用一个极其罕见的预测路径来获取高分，由于随机路径是从分布中采样，这种罕见路径在训练中出现的概率很低，不易被稳定利用。

但注意：图中说的是“**结构性缓解**”，而不是“完全解决”。reward hacking 仍然是开放问题，只是不像 2018 年那么严重。

图片末尾提到的 V-JEPA (Yann LeCun 团队的工作) 用 EMA (指数移动平均) 从训练机制上进一步切断捷径, 这是后续的更高级的改进。

4. Dreamer 的规划方式：潜在空间里的“想象-评分-行动”

图中描述得很清晰：

1. 把**当前真实状态**编码到潜在空间，送入 RSSM。
2. **不与真实环境交互**，只在 RSSM 内部反复滚动预测未来 H 步。
3. 用一个**学到的奖励模型**（也在潜在空间里）给每条想象轨迹打分。
4. 选出**预期累积奖励最高**的动作序列，执行其中的第一步。
5. 重复以上循环。

这个过程完全在潜在空间里进行，速度比真实环境快几个数量级。并且不需要一个单独的“控制器网络”来训练——直接通过在线规划（想象+打分）选出动作。这也是一种避免 reward hacking 的方式（因为没有训练一个固定的 C 网络，每次都是针对当前状态重新规划）。

5. Dreamer V3 的成就：单套超参数打遍 150+ 任务

图中提到 Dreamer V3 用**一套超参数**（同一个配置，没有针对每个任务单独调参），在 Atari、Minecraft、机器人控制等 8 个领域超过 150 个任务上都取得了有竞争力的结果。

这在之前从未实现过。为什么重要？

- 说明 RSSM 架构足够通用，能适应完全不同的环境（像素游戏、连续控制、3D 导航）。
- 世界模型从“每个任务都需要精心调试的玩具”变成了“开箱即用的通用方法”。

这也是为什么 Dreamer 系列被称为世界模型领域的“旗舰工作”。

6. 总结：阶段三解决了阶段二的哪些问题？


阶段二（2018 World Models）的问题	阶段三（Dreamer + RSSM）的解决方案
在像素空间预测，计算量巨大	在潜在空间预测，维度降低上千倍
控制器容易在像素空间找到“漏洞”作弊	潜在空间丢掉了细节，可钻的空子大幅减少
世界模型只能表达确定性的未来	RSSM 的随机路径明确建模不确定性
需要训练一个单独的 C 网络	用在线规划（想象-评分-行动）直接选动作
每个任务需要大量调参	Dreamer V3 单套超参数泛化到 150+ 任务

阶段四：视频即世界（2023+）

2023 年前后，两条平行路线汇聚：**能不能用视频本身来学习世界的物理规律？**

路线 A：JEPA（联合嵌入预测架构）

Yann LeCun 团队走了一条与扩散模型截然不同的路：抛弃像素重建，只在**语义嵌入空间**里做预测。



"我不需要画出你的脸，我只需要知道你是谁。"

Meta 在 2025 年发布的 V-JEPA 2 被明确定位为**"迈向 AGI 的世界模型组件"**：给定动作序列，在语义空间预测未来的视觉表示，不是生成逼真视频，而是理解"如果我这样移动手臂，物体会在哪里"。

路线 B：大规模视频生成

Google 的 Genie、Veo 在 2024 年发布，NVIDIA 的 Cosmos 在 2025 年初跟进。研究者开始追问：这些模型在生成逼真视频的过程中，是不是顺带学到了**空间结构感、物体持久性和粗粒度物理规律**？如果是，它们能不能作为机器人的底层世界模型？

这个问题至今没有确定答案，但已经足够严肃，让两个原本平行的领域坐到了同一张讨论桌前。

这张图片讲的是世界模型发展的**最新阶段**：大约从2023年开始，研究者开始探索**能否直接从海量视频中学习世界的物理规律**，而不依赖手工设计的模拟器或强化学习中的潜在空间模型。它总结了两种正在汇流的路线：**JEPA** 和 **大规模视频生成**。我来帮你拆解。

背景：为什么“视频即世界”成为新的焦点？

前三个阶段（理论奠基、2018统一框架、Dreamer潜在空间革命）本质上都是在**游戏或简单机器人环境**中构建世界模型。但真实世界是无限的、开放的、充满复杂物理规律的。如果能让模型像婴儿一样，只看大量视频（比如YouTube上的日常片段），就能学会“物体恒存”、“重力”、“碰撞”等常识，那世界模型的泛化能力将实现跃迁。

这就是“视频即世界”的愿景：**把世界模型的学习问题，转化为视频预测或视频生成问题。**

路线A：JEPA（联合嵌入预测架构）—— 不画图，只推理

提出者：Yann LeCun 团队（Meta AI）

核心理念：传统生成模型（如扩散模型、VAE）要求模型在**像素空间重建未来帧**——这非常昂贵且充满无关细节。JEPA 放弃像素重建，只在**语义嵌入空间**做预测。

图中的对比

传统方法	JEPA
输入帧 → 编码 → 在像素空间预测下一帧 → 解码（重建像素）	输入帧 → 编码 → 在语义空间预测下一帧的 表示 → 止步于此，不解码
需要精确生成每一个像素（包括噪点）	只需要预测抽象特征（如“球的位置”、“人的姿态”）

关键引文：“我不需要画出你的脸，我只需要知道你是谁。”
——意思是：要理解世界的演变，没必要在像素级上“画”出下一帧；只要能在抽象的语义层面预测出“接下来会发生什么类型的场景”就够了。

V-JEPA2（2025年发布）

Meta 明确将它定位为“**迈向AGI的世界模型组件**”。它的工作方式：

- 给模型一个动作序列（例如“手臂向上移动10厘米”）。
- 模型不输出视频，而是输出**未来视觉表示的语义特征**，比如“物体会出现在新位置”。
- 优势：训练效率极高（不需要解码），且强制模型抓住**因果结构**而非像素统计。

与 Dreamer 的潜在空间对比：Dreamer 的潜在空间是从 VAE 学来的、仍然服务于像素重建（为了能解码回图像）。而 JEPA 的语义嵌入空间**完全不追求可解码性**，只追求对预测任务有用。这更接近于“理解”而非“想象画面”。

路线B：大规模视频生成 —— 让模型在生成中“偷学”物理

代表模型：

- **Google Genie (2024)：**从单张图片生成可交互的2D游戏世界。它实际上学习了一个潜在的“动作”空间，用户可以通过操作让画面变化。
- **Google Veo (2024)：**高质量视频生成模型，能生成长时间、一致的视频。
- **NVIDIA Cosmos (2025)：**专为物理AI/机器人训练设计的视频生成世界模型。

核心研究问题

图片里问得非常精准：

这些模型在生成逼真视频的过程中，是不是顺带学到了空间结构感、物体持久性和粗糙物理规律？如果是，它们能不能作为机器人的底层世界模型？

什么叫“顺带学到”？

视频生成模型的训练目标只是“预测下一帧像素”。但为了做到这一点，模型被迫在内部学会一些隐式表征：例如物体不应该凭空消失（持久性）、物体运动应该大致符合重力、遮挡关系要合理。这些恰好就是世界模型所需的物理常识。

但有没有真正学会？

目前没有确定答案。很多研究发现视频生成模型在长期预测中会崩溃，物体变形、物理不一致。但也有人证明，通过规模化的训练（如Veo、Cosmos使用海量真实视频），模型确实展现出一定程度的物理一致性。

如果答案是“是”，那意义重大

- 机器人不再需要手工搭建模拟器或收集昂贵的示范数据，可以直接利用互联网视频作为“教材”，学会常识物理。
- 视频生成模型本身就是世界模型：输入当前帧+动作，输出未来帧，就能用于规划（比如想象几种可能的未来，选择动作）。

这也是为什么图片说“这个问题让两个原本平行的领域——计算机视觉/视频生成 与 强化学习/机器人——走到了同一张讨论桌前”。

两条路线的核心差异

维度	JEPA (路线A)	大规模视频生成 (路线B)
预测目标	语义嵌入空间中的表示	像素空间中的未来帧
是否生成画面	否（只预测特征）	是（生成视频）
训练效率	高（无需解码）	低（需要生成大量像素）
对人类可解释性	差（人看不懂嵌入）	好（生成的视频人可看）
当前主要挑战	如何定义/学习“语义空间”	物理一致性不足、计算成本高
代表机构	Meta (LeCun)	Google, NVIDIA

总结：阶段四的意义

阶段四标志着世界模型的研究从**游戏/仿真环境**走向**真实世界的海量视频**。两条路线都在探索同一个根本问题：

我们能否让机器像婴儿一样，通过观察世界（观看视频）就学会物理常识，从而获得一个通用的、无需手工设计的世界模型？

- **JEPA** 选择了一条“轻量级”路径：只预测抽象特征，放弃像素，追求效率和因果理解。
- **视频生成** 选择了一条“重渲染”路径：坚持生成像素，希望模型在“画”的过程中被迫学会物理。

目前还没有定论哪条路最终会胜出（或者会融合）。但正如图片结尾所说：这个问题足够严肃，已经让两个曾经互不往来的领域坐到了同一张桌子前。未来几年，世界模型很可能就是某种**混合了视频生成与语义预测的大规模预训练模型**。

五、为什么偏偏是最近两年火了？

时代三的 Dreamer V1 是 2019 年的，时代四的视频生成 2023 年就起步了。为什么偏偏 2024–2025 才成了每个 AI 会议的主角？

不是某个单点突破，而是三条线刚好同时成熟，撞到了一起。

第一条：视频生成突然变强。 Genie、Veo、Cosmos 的出现（上文时代四）让视频生成质量在短时间内大幅提升。但质量提升带出了一个更深的追问：生成质量高不等于物理理解深，这批模型能不能作为机器人的底层

世界模型？这个问题催生了大量跨领域研究投入，也是为什么 2024 年后世界模型的讨论同时出现在视频生成和机器人两个会议上。

第二条：具身智能遇到数据瓶颈。通用机器人训练需要大量遥操作数据，成本极高，世界模型提供了"从无标注视频间接学习"的绕路方案。

第三条：自动驾驶验证了"反事实仿真"的商业价值。Wayve 的 GAIA-1 已经在工业级证明：用世界模型生成罕见危险场景的合成数据，比单纯累积路测里程效率更高，这条路径的商业逻辑已经跑通。

上一次世界模型热（2018–2020）是学术界主导的，在游戏里证明可行性，落地很遥远。这一次（2024+）工业界和学术界同时入场，因为它已经触碰到了真实的成本瓶颈和安全需求。

六、五大技术路线，一次讲清楚

2023 年以后，世界模型分化出五条路线，每条面对的核心权衡都不一样：RNN/RSSM 追求样本效率、Transformer 追求长程建模、Diffusion 追求生成质量、JEPA 追求语义理解、Embodied WM 追求数据效率。选哪条，取决于你的任务对哪个瓶颈更敏感：


架构对比速览

架构	代表模型	核心机制	最大优势	最大局限
RNN/RSSM	Dreamer V1–V4	GRU 确定性路径 + 随机潜变量采样	样本高效，支持在线 RL	长序列记忆弱
Transformer	STORM (2023)	离散 token + 因果注意力	长程依赖，并行训练	计算量二次增长
Diffusion	Diamond (2024)	U-Net 逐步去噪	生成质量最高	推理慢，不可微
JEPA	V-JEPA 2 (2025)	语义空间预测，不生成像素	高效，语义理解强	无可视化输出
Embodied WM	DreamDojo (2026)	人类视频预训练 + 连续潜在动作	利用海量无标注视频	大规模部署验证有限

STORM：把游戏帧变成"句子"

STORM (NeurIPS 2023, arXiv:2310.09615) 的思路，是把 GPT 处理文字的方式搬到视频帧上。

GPT 能预测"下一个词"，因为词是离散的、可以用概率分布精确建模。STORM 用**分类 VAE**把每一帧压缩成一个**离散潜变量**，就像把一首歌的某个小节描述成"这是 A 段高潮"，而不是保留"这 4 秒钟的完整波形数据"。再把这个离散编码和当前动作合并成单个 token，送给 Transformer 处理。



单 token 设计让序列长度大幅缩短（同期的 IRIS 方法每帧产生 16 个 token，STORM 只用 1 个），训练速度大幅提升。在 Atari 100k 基准上，STORM 以 **126.7% 平均人类标准化分数（HNS, Human Normalized Score, 以人类玩家水平为 100% 的归一化得分）** 创造了当时不依赖额外规划算法的方法中最高记录，训练只需要单块 RTX 3090 约 4 个小时。

1. STORM 的核心思想：帧 → 离散编码 → 类似 GPT 预测下一个 token

背景： GPT 这类语言模型之所以成功，是因为自然语言是**离散的**（有限的词表），可以轻松地用**概率分布**建模，并自回归地预测“下一个词”。

如果把游戏视频帧也变成离散的“词”，那么就可以直接用 Transformer（GPT 的架构）来预测“下一帧的离散编码”，从而得到一个世界模型。

STORM 的做法：

- 用一个 **分类 VAE**（Categorical VAE，有时也叫 VQ-VAE 的变体）把每一帧图像压缩成一个**离散潜变量**（discrete latent variable）。
类比：不是保留一秒钟的完整波形数据，而是说“这是 A 段高潮”。
- 这个离散编码只有一个 token（例如一个 0~511 之间的整数）。
- 把当前帧的 token 和当前动作合并成**单个 token**，输入到 Transformer。
- Transformer 学习预测**下一个 token**（即下一帧的离散编码）。
- 解码器可以将预测出的 token 还原为完整的游戏画面（用于人类观看或评估）。

与同期方法 IRIS 的对比： IRIS 每帧产生 16 个 token（例如把画面分成 4×4 的块，每个块一个 token），而 **STORM 只用 1 个 token**，序列长度大幅缩短，训练速度更快。

2. 为什么“单 token 设计”很重要？

- **序列长度**：在 Transformer 中，计算复杂度与序列长度成平方关系。每帧 1 个 token 意味着处理 1000 帧只需要 1000 个 token；如果每帧 16 个 token，就需要 16000 个 token，计算量大很多。
- **训练速度**：STORM 在单块 RTX 3090 上训练约 4 小时，就能在 Atari 100k 基准上达到 **126.7% 的人类标准化分数 (HNS)**。
HNS 以人类玩家水平为 100%，126.7% 意味着超越了人类平均水平。
并且这个成绩是 **不依赖额外规划算法** 的情况下取得的（即纯靠世界模型 + 简单策略，没有像 Dreamer 那样做在线规划），在当时同类型方法中是最高的。

3. STORM 与 Diamond（扩散模型）的核心区别

维度	STORM	Diamond
预测方式	离散 token 分类（类似 GPT）	连续像素去噪（扩散）
单帧计算	一次前向传播（快）	约 10 步迭代去噪（慢）
输出质量	压缩后还原，可能有损	高保真像素级
可微性	离散 token 不可微（但可通过 Gumbel softmax 或直通估计器近似）	去噪过程不可微
吞吐量	高（因为单 token + 单步）	低（约一个数量级差距）
代表成绩 (Atari 100k)	126.7% HNS（无额外规划）	146% HNS（可能需要额外规划？原文未明确，但视觉质量更高）

注意：Diamond 的 146% HNS 可能是在相同的基准上，但 Diamond 使用了扩散模型，生成的帧质量更高，但计算开销也大。STORM 的优势在于**训练和推理都更高效**。

4. STORM 在五大路线中的位置

根据之前总结的五大路线：

- **RNN/RSSM**：Dreamer 系列（潜在空间，高效率）
- **Transformer**：STORM 就属于这一类——它用 Transformer 替代 RNN，通过离散 token 预测未来。
- **Diffusion**：Diamond 属于这一类。
- **JEPA**：Meta 的语义预测路线。
- **Embodied WM**：机器人专用。

所以 STORM 是 **Transformer 路线** 的代表作之一，证明了“把视频帧当作语言”可以高效地训练世界模型，并且取得顶尖的强化学习效果。

Atari 100k 是一个非常苛刻的基准测试，旨在评估 AI 在极少量数据下的**学习效率**。它像一个“速成班”，要求 AI 在“接触”新游戏时，只有相当于人类玩家**2小时**的游戏时间，之后便直接评估其表现。

🎮 测试“赛场”：Atari 2600

这个基准测试使用的游戏来自经典的**Atari 2600**游戏机，其中最常采用的是 **26款**风格和挑战各异的游戏。这些游戏要求 AI 同时具备视觉识别、短期记忆和长期策略规划等多种能力，是一个能全面考察通用AI能力的“综合赛场”。

🧐 为何而测：筛选“高效”的算法

设立此基准的根本目的，是解决强化学习（RL）的一个核心痛点：**样本效率**。

- **传统RL的“题海战术”**：如DeepMind著名的DQN算法，需要在《蒙特祖马的复仇》这款游戏中“练习”惊人的**5亿步**环境交互，其学习模式如同依靠海量“题海战术”来应试。
- **Atari 100k的“速成模式”**：相比之下，Atari 100k将预算限制在 **100,000步**（对应 **400,000帧**游戏画面），仅为前者的 **1/500**。只有算法本身学习效率足够高，才能在如此少的尝试中掌握游戏精髓。

📏 评分标准：人类水平（HNS）

为了让大家能公平比较，所有算法的得分都会被归一化为 **Human Normalized Score (HNS)**。

- **计算公式**：
$$\frac{\text{AI得分} - \text{随机操作得分}}{\text{人类得分} - \text{随机操作得分}}$$
- **分数解读**：
 - **0**：表示AI的表现和纯随机操作（Random）一样。
 - **100%**：表示AI的得分达到了人类专业测试者的水平，是衡量是否“学会”的重要标杆。
 - **超过100%**：表示AI在该游戏上的表现**超越了人类水平**。

🔧 如何使用：严格的测试规范

为确保测试的公平性，该基准制定了一套**标准化流程**：

1. **游戏环境**：基于 **Arcade Learning Environment (ALE)** 这个标准的Atari游戏模拟器。
2. **任务数量**：通常在26个游戏上全面评估。
3. **预算上限**：严格限制在 **100,000步**环境交互。
4. **多轮测试**：每个游戏通常使用 **5个不同的随机种子**来训练和测试，以抵消随机性对结果的影响。
5. **结果汇报**：最终分数取5次测试的**平均值和置信区间**等统计指标，而不是单次最大或最小值，以确保评估的可靠性。

🏆 成绩榜：优秀“速成”选手

在严格的规则下，许多顶尖算法脱颖而出，其中你已有所了解的**DIAMOND**和**DreamDojo**表现尤为出色。

算法	来源	技术特点	在Atari 100k上的表现
DIAMOND	日内瓦大学 (2024)	使用 扩散模型 精确预测未来画面	HNS 1.46 ，多项任务超人类水平
DreamDojo	NVIDIA (2026)	从 44,000小时 人类视频中学习物理规律	展现强大的零样本泛化能力
DreamerV3	谷歌 (2023)	在压缩的 潜在空间 高效模拟世界	首个用 一套参数 在150+任务上获顶尖表现
STORM	(2023)	将画面转为 离散代码 ，用Transformer预测	无需前瞻搜索创纪录，达 126.7% HNS

💡 总结


总的来说，Atari 100k 通过限制交互次数、采用标准化的评估流程和以人类水平为参照的评分标准，成功地将研究焦点从单纯的“玩得更好”转向更富有现实意义的“**学得更快**”。

Diamond：用扩散模型“画出”下一帧

Diamond (NeurIPS 2024, arXiv:2405.12399) 走了另一条路：不做离散压缩，直接用扩散模型逐步“去噪”出下一帧。

扩散模型 (Diffusion Model) 的核心逻辑是：先把真实图像加噪声破坏掉，再训练模型把噪声一步步还原。在世界模型场景里，以历史帧和当前动作作为条件，扩散模型“去噪”的结果就是下一帧的预测。

Diamond 选择了其中最右边的方案：通过**交叉注意力**把动作信息注入 U-Net，让去噪过程以动作为条件：



Diamond 在 Atari 100k 上以**平均 HNS 146%**超越了此前所有世界模型方法，生成的视频帧视觉质量也是五种架构中最高的。

代价是：每生成一帧需要多次神经网络前向传播，计算开销远高于 STORM 这类单次前向传播的方法（实测帧生成吞吐量相差约一个数量级）；而且生成过程不可微，难以直接与策略优化对接。

1. Diamond 的核心思路：用扩散模型“画”出下一帧

扩散模型 (Diffusion Model) 本质上是学习一个“去噪”过程：

- 训练阶段：对真实图像逐步加噪声，直到变成完全随机噪声；让模型学会**逆向过程**：从噪声一步步恢复原图。
- 推理阶段：从一个随机噪声出发，迭代多步（比如 10 步、50 步）得到一张清晰的图像。

在世界模型中的用法：不是任意生成图像，而是以**历史帧和当前动作作为条件**，让扩散模型去“去噪”出一个**符合该条件的下一帧**。也就是说，模型看到过去和现在，再结合我要做的动作，就能“想象”出未来画面。

Diamond 具体采用的架构是图中最右边的方案：**通过交叉注意力 (Cross-attention) 把当前动作信息注入 U-Net**。U-Net 是扩散模型里常用的骨干网络，它能同时看到历史帧（作为条件）和当前动作，然后一步步去噪生成下一帧。

2. Diamond 的优势

(1) 生成质量极高

在 Atari 100k 基准上，Diamond 的 **平均 HNS (人类标准化分数) 达到 146%**，超越了此前所有世界模型方法。HNS 是把人类玩家水平定为 100%，146% 意味着大幅超越人类平均表现。

同时，它生成的视频帧**视觉质量在五大架构中是最高的**——几乎看不出是预测出来的，清晰、连贯、细节丰富。

(2) 能保留像素级细节

因为扩散模型直接操作像素（或像素的潜空间），它不像 STORM 那样先做有损压缩，因此能保留纹理、光照、边缘等细微信息。这对于需要视觉反馈的任务（比如自动驾驶中的路标识别）可能很重要。

3. Diamond 的代价（也是致命短板）

(1) 计算开销极大

- **每生成一帧需要多次神经网络前向传播**（例如 10 步迭代）。每一步都走一遍完整的 U-Net。
- 相比之下，STORM 这类**单次前向传播**的方法（例如直接输出离散 token 的 logits）的**帧生成吞吐量比 Diamond 高约一个数量级（10 倍以上）**。
- 这意味着 Diamond 很难用于实时交互（如真实机器人控制、在线游戏），因为生成一帧可能就要几十毫秒甚至更长。

(2) 生成过程不可微

扩散模型的去噪过程包含随机采样和多步迭代，中间的采样操作不是可微的。因此 **Diamond 的预测结果无法直接与策略网络（或者规划器的梯度）对接**。换句话说，你不能像训练一个 RNN 那样，把世界模型的损失和策略的损失一起反向传播。这限制了它在“端到端联合优化”场景下的使用。

4. Diamond vs. STORM：两种极端的对比

维度	STORM	Diamond
预测方式	离散 token 分类（类似 GPT）	连续扩散去噪（像素/潜空间）
对帧的处理	压缩成一个离散码，丢掉大量细节	保留/生成高保真像素
推理速度	快（单次前向）	慢（多步迭代，约 10× 差距）
生成质量	有损压缩，还原后模糊/带伪影	最高质量，接近真实画面
可微性	离散 token 不可微（但可以用 Gumbel softmax 近似）	去噪过程不可微，更难突破
Atari 100k HNS	126.7%（无额外规划）	146%（最高视觉质量）
训练资源	单卡 RTX 3090，4 小时	需要更多（论文未细说，但扩散通常更贵）
适用场景	对速度要求高、可接受有损视觉	对预测画面质量要求极高、不关心推理时间

5. 结合之前的“五大路线”

在五大路线中：

- **STORM 属于 Transformer 路线**（把帧当作词，自回归预测）。
- **Diamond 属于 Diffusion 路线**（用去噪生成未来帧）。

两条路线都在 2023–2024 年取得了突破，但它们的取舍非常清晰：

- 如果你要训练一个**实时交互的智能体**（比如机器人、自动驾驶），STORM 这类快速方法更现实。
- 如果你需要**生成高质量的模拟画面**（比如电影特效、自动驾驶仿真中的传感器数据），并且不在乎每帧的耗时，Diamond 的扩散方法更合适。

一、核心类比：画家与“橡皮泥草图”

想象你是一个画家，要根据当前游戏画面和按下的“右”键，画出下一帧。

- **传统直接预测法**：让你直接提笔画一张清晰的下一帧。这很难，因为你要精确到每个像素、纹理、光影，稍有偏差就会模糊。

- **扩散预测法 (Diamond)**：先给你一团**随机噪声**（像一团灰色橡皮泥，什么形状都不是）。然后你根据“当前画面+动作”作为参考，**一步步把这团噪声捏成清晰的下一帧**。每一步你只做微小调整（比如把一团模糊变成稍微像物体轮廓）。经过大约10步，一幅高质量的预测画面就诞生了。

为什么要从噪声开始？

因为从完全随机出发，模型有更大的“创作自由度”，能生成细节丰富、逼真的结果；而一步预测容易因为“平均效应”变得模糊。扩散模型的训练过程，就是让模型学会“如何根据条件，一步步把噪声变回清晰图像”。

二、训练阶段：模型学的是“去噪”，而不是直接输出下一帧

在训练时，我们有真实的历史帧 (x_t)、动作 (a_t)，以及**真实下一帧** (x_{t+1})（作为“标准答案”）。

1. **加噪**：对真实的 (x_{t+1}) 逐步添加高斯噪声，得到一系列越来越模糊的版本 ($x_{t+1}^{(1)}, x_{t+1}^{(2)}, \dots, x_{t+1}^{(K)}$)，最后一步变成纯噪声。
2. **条件输入**：把历史帧 (x_t)（可能多帧）和动作 (a_t) 作为**条件**，和当前噪声版本一起送入一个神经网络 (U-Net)。
3. **训练任务**：U-Net 不直接输出“下一帧”，而是输出**当前噪声版本中混入了多少噪声**（或者说，预测如何去除一部分噪声）。
 - 例如：给模型看 ($x_{t+1}^{(5)}$)，让它预测出导致这一步的噪声，从而能够倒推出更干净的一步 ($x_{t+1}^{(4)}$)。

关键领悟：模型从来没有被要求“看 (x_t, a_t) 直接输出 (x_{t+1})”。它被训练成一个**通用的去噪器**：给它一张带噪图像和条件，它就能告诉你“如何减少一点噪声”。当条件恰好是“当前帧+动作”时，从纯噪声开始迭代去噪，自然就会得到一个合理的下一帧。

三、推理阶段：从“纯噪声”一步步画出下一帧

当你已经训练好一个以 (x_t, a_t) 为条件的去噪网络后，就可以这样预测下一帧：

1. 从一张**纯随机噪声**图片开始（与游戏画面尺寸相同）。
2. 重复以下步骤约 **10 次**：
 - 把当前噪声图 + 条件 (x_t, a_t) 输入 U-Net。
 - U-Net 预测出“应该去除多少噪声”。
 - 按预测结果减掉一部分噪声，得到稍微干净一点的新图。
3. 最终得到的图片就是模型“想象”出的下一帧 (x_{t+1})。

为什么这能工作？

因为在训练时，模型见过大量 (x_t, a_t, x_{t+1}) 的三元组，并学会了“如果条件是这个，那么从噪声出发，去噪的路径就应该走向那个真实帧”。推理时即使没有真实 (x_{t+1}) 作为目标，模型也能依据条件，一步步走向统计上最合理的下一帧。

四、与直接预测下一帧的核心区别

方法	训练目标	推理过程	优点	缺点
直接回归（如 CNN）	最小化 $(预测帧 - 真实帧 ^2)$	一次前向传播得到帧	快	易模糊，细节差
扩散模型（Diamond）	学习每一步的噪声预测	多步迭代去噪	生成质量高，细节丰富	慢，不可微

直观总结：

- 直接回归：逼着模型“猜一个最可能的平均值”，结果像“拖影”或“模糊照片”。
- 扩散模型：让模型“从噪声中慢慢雕刻”，像艺术家创作，结果清晰且真实。

五、一句话回答你的疑惑

“先加噪声再去噪”和“预测下一帧”之间的桥梁是：


扩散模型将“条件生成下一帧”这一任务，重新定义为“以当前帧和动作为条件的、从噪声逐步去噪的过程”。

在训练时，模型学会的是在各种噪声程度下根据条件去噪；在推理时，从纯噪声开始，应用学到的去噪能力，迭代后自然得到下一帧预测。

V-JEPA 2：不画画，只理解

V-JEPA 2（Meta，2025，arXiv:2506.09985）是最“另类”的一个：它根本不生成图像。

它的训练目标是：给定一段视频中可见的时空块，预测被遮挡的时空块的**语义表示**，而不是预测像素值。V-JEPA 2 在此基础上进一步加入动作条件，使模型能够回答“执行这个动作序列之后，视频的语义表示会怎么变”。



这里有一个陷阱：如果两个编码器完全同步更新，模型会很快找到一个捷径，“把所有输入映射到同一个向量”就能让预测误差接近零，这叫**表示坍塌 (Representation Collapse)**。而**EMA (指数滑动平均, Exponential Moving Average)** 是堵住这个捷径的关键：目标编码器的参数不直接跟着梯度走，而是每步只向另一个编码器“靠近一小步”（比如 99% 保留旧值，1% 吸收新值），像一个永远慢半拍的影子。两者永远不同步，模型就无法通过输出固定向量来“蒙混过关”。

V-JEPA 2 被 Meta 明确定位为世界模型的基础组件，而不是视频生成器。它的优势在于对物理世界的**结构性理解**：不需要关心光照、纹理等像素级细节，直接在语义层面建模“这个物体在哪里、手是否握住了它”。

1. V-JEPA 的核心哲学：不画画，只理解

JEPA = 联合嵌入预测架构 (Joint Embedding Predictive Architecture)，由 Yann LeCun 团队提出。它的训练目标不是“下一帧长什么样”，而是“下一帧的**语义表示**是什么”。

具体做法（图中第一段）：

- 给定一段视频，把其中一部分**时空块**（比如画面中间的一个方块区域）**遮挡住**。
- 让模型根据**可见的时空块**，去预测**被遮挡部分的语义表示**（而不是原始的像素值）。
- 所谓“语义表示”，就是一个向量，它概括了“这里有什么物体、在什么位置、做什么动作”这类高层信息，而不关心具体的光照、纹理、噪点。

加入动作条件（图中第二段）：

- V-JEPA 2 进一步引入**动作条件**。模型被训练成：给定当前视频片段 + 一个动作序列，预测**执行动作后视频的语义表示会变成什么**。
- 这就让它非常适合作为**世界模型**：智能体可以问“如果我向左转，接下来会看到什么场景（在语义层面）？”然后基于这个预测进行规划。

2. 关键陷阱与解决方案：表示坍缩 + EMA

图中用一个非常形象的例子解释了 JEPA 训练面临的核心难题。

问题：表示坍缩 (Representation Collapse)

- 如果两个编码器（一个处理可见部分，另一个处理被遮挡部分）使用**完全相同的参数并同步更新**，模型会找到一个**作弊捷径**：把所有输入都映射到**同一个常数向量**。这样无论看到什么，预测误差都是零，但模型实际上什么都没学到。
- 这就是“表示坍缩”——所有表示失去区分度。

解决方案：EMA (指数滑动平均)

- 训练时维护两个编码器：**在线编码器**（随梯度更新）和**目标编码器**（用于生成预测目标）。
- 目标编码器的参数**不通过梯度下降更新**，而是**每一步都向在线编码器的参数“靠近一小步”**：
[
$$\theta_{\text{target}} \leftarrow \tau \cdot \theta_{\text{target}} + (1 - \tau) \cdot \theta_{\text{online}}$$

]
其中 (τ) 通常接近 1（例如 0.999），意思是目标编码器**很慢地追随**在线编码器，像“永远慢半拍的影子”。
- 这样一来，两个编码器**永远不会完全同步**，模型就无法通过输出恒等向量来“蒙混过关”，必须真正学习有意义的语义表示。

EMA 这个技巧最早在 MoCo、BYOL 等自监督学习工作中被广泛使用，V-JEPA 2 将其继承下来，保证了训练的稳定性。

3. V-JEPA 2 的定位：世界模型的基础组件，而非视频生成器

图片最后一段明确指出：

V-JEPA 2 被 Meta 明确定位为世界模型的基础组件，而不是视频生成器。

这意味着：

- 它不输出人眼可看的视频帧，只输出语义向量。
- 但智能体（比如机器人）可以直接在这些语义向量上做**规划、推理、决策**，因为语义空间已经包含了“物体在哪里、手是否握住它”等关键信息，而丢掉了纹理、光照等无关细节。

- 这种设计的优势是**极高的计算效率和泛化能力**：不需要去拟合像素，模型更容易学到不变的因果结构。

4. V-JEPA 2 与其他路线的对比

维度	V-JEPA 2	STORM	Diamond
预测目标	语义表示（向量）	离散 token	像素帧
是否生成人眼可读图像	否	是（解码后）	是
计算效率	极高（只算低维向量）	较高	很低（多步去噪）
可解释性（对人）	差（只能看数值）	中	好（画面清晰）
对物理规律的理解	聚焦于结构，忽略纹理	中等（依赖压缩质量）	细节丰富，但易过拟合纹理
训练稳定性	需要 EMA 防止坍缩	稳定（分类交叉熵）	扩散训练较稳定


DreamDojo：从人类视频里“偷学”机器人技能

DreamDojo (NVIDIA, 2026, 预印本, arXiv:2602.06949) 面对的是机器人领域最现实的问题：机器人的操作数据，贵到离谱。

采集高质量机器人遥操作数据，需要专业硬件、熟练操作员、真实物理场景，成本极高。但互联网上有数以万小时计的人类日常操作视频（Ego4D 等公开数据集已超过 44,000 小时），远超机器人遥操作数据集的规模。

DreamDojo 的思路：先在这批人类视频上做大规模预训练，学到物理交互的基本规律（重力、物体碰撞、手的运动方式），再在少量机器人数据上微调。人类和机器人的形态不同，但物理规律一样，这是迁移的前提。

动作标注的问题怎么解决？用**连续潜在动作**（continuous latent actions）作为代理：从相邻两帧之间的差异里自动提取一个几十维的向量，表示“帧与帧之间发生了什么类型的变化”。它不是关节角度，也不是力矩，而是模型从视频里自动发现的抽象运动模式，绕过了逐帧手工标注的需要。



最终，DreamDojo 在 640×480 分辨率下达到 **10.81 FPS 的推理速度**，满足实时机器人控制的基本要求，并展现出跨环境零样本泛化能力。

DreamDojo的核心在于用了一种新思路，解决了机器人训练领域一个根深蒂固的难题：**高质量机器人训练数据极度匮乏，而互联网上人类日常活动的视频却异常丰富，如何将它们有效利用起来？**

它的做法是让机器人先“观摩”海量的人类视频来学习通用的物理规律，掌握“直觉物理学”，然后再通过少量专门的机器人数据进行“精修”，以适应自身硬件。

💡 为什么传统机器人“教”起来这么难？

这背后是传统机器人“无模型强化学习”（Model-Free RL）范式的根本制约。它就像一个必须亲自无数次尝试和犯错才能学会走路的孩子，每一次交互都在真实世界里进行，导致数据成本**极其高昂**。

- **数据采集昂贵**：需要真实环境、专业设备与操作员（比如你之前看到的“遥操作”）。
- **硬件损耗巨大**：机器人在试错中会磨损、损坏。
- **安全性风险高**：许多危险动作无法在现实中进行训练。

而DreamDojo采用的“世界模型”方法，正好是你之前看过的核心思想：**让智能体先在“脑子”里模拟练习，再拿到现实中验证。**

它直接从**44,000小时**的第一人称人类视频中学习，包括做饭、整理、维修等各种日常场景。这个数据集的规模（时长是同类数据集的**15倍**，涵盖技能种类是**96倍**，场景数量是**2000倍**）和视角，能让AI学习到远超实验室所能模拟的物理交互。

🔑 核心突破：如何“听懂”无声的动作语言？

海量的人类视频虽好，但它缺少最关键的信息：**动作标签（Action Label）**。这就像看一部只有画面、没有声音的电影，AI光看像素变化，无法理解背后的动作逻辑。

为了解决这个难题，DreamDojo引入了一项名为**连续潜在动作（Continuous Latent Actions）**的技术。可以把它想象成一个智能解码器：它不依赖预设的动作类别，而是直接从相邻视频帧的**视觉变化**（如物体的位移、形状变化）中，自动“推断”出一个抽象的、低维度的动作指令。

这个过程，就像你把一首歌的“完整波形数据”交给模型，让它自己学懂其中的“乐谱”。它不是人类给的，却是模型能理解的“动作语言”。

这样一来，AI不仅能学会物体移动、变形等物理规律，还能建立起精确的“**动作-结果**”因果模型，这就是它被称为“世界模型”的根本原因。

✦ 从“看到”到“做到”：完整的训练流程

你可以把DreamDojo的学习过程理解为一个“通识教育”加“专业深造”的过程：

- 1. **预训练阶段 - “通识教育”**：模型在海量的、没有动作标签的人类视频上进行学习，掌握通用的物理规律和物体交互方式。
- 2. **后训练阶段 - “专业深造”**：在掌握了基础物理知识后，模型再通过小规模的、带有特定硬件指令（如关节角度）的机器人数据进行微调，学会如何用自己的“身体”去复现那些学到的动作。

🚀 它的能力有多强？带来了哪些新可能？

经过这样训练的DreamDojo，展现出强大的通用性和实时性：

- **强大的泛化与精准模拟**：面对从未见过的物体和环境，DreamDojo也能做出符合物理逻辑的反应。它甚至达到了惊人的**99.5%** 的模拟与现实相关性，让机器人可以在虚拟世界中安全、高效地进行策略评估和规划。
- **实时的“想象力”**：经过模型蒸馏加速后，DreamDojo能在**640×480**分辨率下以**10.81帧/秒（FPS）** 的速度实时运行，足以支撑起实时的远程操控（Teleoperation）。

总的来说，DreamDojo的核心思想是让AI通过对海量人类行为的观察，先构建一个通用的物理世界模型，再用极少的机器人数据进行适配，从而大规模地训练出更通用、更智能的机器人。

这背后的关键技术创新——连续潜在动作，帮你解答了“模型如何在无动作标签的人类视频里学到‘动作-结果’因果关系”的疑惑。如果对这一关键机制的具体细节想有更深入的了解，我们可以随时接着聊。

如何选择？一张决策图

你的首要关注点	推荐架构	理由
样本效率最高（真实交互尽量少）	RNN/RSSM (Dreamer)	潜在空间预测，样本效率经过充分验证
需要记住很久以前的线索	Transformer (STORM)	注意力机制天然支持长程记忆
需要生成极其逼真的画面	Diffusion (Diamond)	生成质量无可匹敌，即使慢一些也可以接受
追求最快推理速度，不需要看画面	JEPA (V-JEPA 2)	只在语义空间操作，极轻量
有海量未标注视频，希望机器人从中学习	Embodied WM (DreamDojo)	目前唯一能大规模利用人类视频的方法

七、吵起来了：世界模型真的是正确答案吗？

五个架构，五条路线，每条都有人在押注、在融资、在发论文。但有一个问题，这些论文都没有回答：世界模型，真的是正确的方向吗？AI 领域围绕这个问题有三种截然不同的声音，值得分开来听。

第一种声音：世界模型是唯一正确的路

这是 Yann LeCun 和谢赛宁的立场。AMI Labs 于 2025 年 12 月成立，LeCun 担任执行董事长，谢赛宁担任首席科学官，截至 2026 年 3 月完成超过 10 亿美元融资，明确对标“以 LLM 为中心”的硅谷主流。别人融十亿是为了买卡训 LLM，他们融十亿是为了证明大家训 LLM 训错了方向。

谢赛宁的比喻流传很广（访谈原文）：

“语言是一剂‘鸦片’。它有用，但它是捷径。如果你一直靠拐杖走路，你就没办法训练大腿的肌肉。”

LeCun 的表述更详细（见 2022 年技术报告 A Path Towards Autonomous Machine Intelligence）：LLM 处理的是人类发明的符号系统，是对世界的二次抽象；真正的智能需要直接从连续的感官信号中建模物理世界。他的核心论断是：**表征是世界模型最重要的部分**，语言和像素都只是表征的输出接口，而不是基础。

AMI Labs 的技术选择是非生成式的 JEPA 路线，不生成像素，直接在语义空间里预测状态变迁。他们的赌注是：五年后，今天 LLM 主导的格局会被证明是一段弯路。

这段话其实在讨论一个根本性的路线之争：**AI 的下一个突破，是靠更大的语言模型（LLM），还是靠能理解物理世界的“世界模型”**？你摘录的是第一种声音——最激进、也最反主流的一派，以 Yann LeCun 和谢赛宁为代表。下面我帮你梳理他们的核心逻辑。

1. 他们是谁？在做什么？

- **Yann LeCun**：Meta 首席 AI 科学家，图灵奖得主，卷积神经网络发明人之一。长期批评 LLM 路线，认为它不能通向真正的智能。
- **谢赛宁**：原纽约大学助理教授，曾任 Facebook AI Research 研究员，以视觉表征学习（SimCLR、ResNeXt）闻名。2025 年底共同创立 **AMI Labs**，LeCun 任执行董事长，谢赛宁任首席科学官。
- **AMI Labs**：在 2025–2026 年融资超过 10 亿美元，明确对标“以 LLM 为中心的硅谷主流”。这笔钱不是去买更多 GPU 训练更大的 GPT，而是用来证明 **“大家训练 LLM 可能训错了方向”**。

2. 他们的核心论点：语言是“鸦片”，靠拐杖走路练不出大腿肌肉

谢赛宁的比喻（很关键）

“语言是一剂‘鸦片’。它有用，但它是捷径。如果你一直靠拐杖走路，你就没办法训练大腿的肌肉。”

解读：

- 语言是人类对世界的一种高度抽象、离散化的符号系统。它可以高效传递知识，但本身是**二手的、被压缩过的**。

- 今天的大模型（GPT 等）只学习这些符号之间的统计关系，从未**直接**接触过物理世界（光、力、触觉、时间连续性等）。
- 依赖语言作为唯一的训练信号，就像一个人一直拄着拐杖走路——短期方便，但**大腿肌肉（真正的物理常识、因果推理能力）永远不会发育**。

LeCun 的技术论断

来自他 2022 年的经典文章 *A Path Towards Autonomous Machine Intelligence*：

“真正的智能需要直接从**连续的感官信号**中建模物理世界。语言只是对世界的一次二次抽象。”

- LLM 处理的是人类已经写好的文本，这些文本是**对真实世界观测的符号化记录**。模型再厉害，也只是在“符号的符号”上做模式匹配。
- 婴儿不需要语言就能学会物体恒存、重力、碰撞——这些是**世界模型**提供的能力。智能的根基是**预测物理世界的变化**，而不是预测下一个词。

3. 他们押注的具体技术路线：JEPA（非生成式）

- **JEPA**：联合嵌入预测架构，只在语义空间做预测，不生成像素（也就是你之前看到的 V-JEPA 2 那条路）。
- 为什么不生成像素？
LeCun 认为，生成像素（扩散模型、VAE 等）是浪费计算在无关细节（纹理、光照）上。智能体真正需要的是**抽象状态**——比如“球在左边”而不是“球占据哪些像素”。
- 所以 AMI Labs 的技术选择是 **非生成式的世界模型**，强调“**表征是世界模型最重要的部分**”——先学会对世界的好表征，然后在表征空间里预测未来、规划行动。

4. 他们的赌注有多大？

“五年后，今天 LLM 主导的格局会被证明是一段弯路。”

- 目前硅谷主流：继续 Scaling Law，把更多的数据和算力扔给 Transformer，靠更大的上下文窗口、更长的推理链来“涌现”出智能。
- LeCun / 谢赛宁的挑战：这个方向已经碰到瓶颈——LLM 缺乏物理常识、无法真正规划、会产生幻觉，因为它们的底层没有**世界模型**。
- 他们赌的是：**下一代 AI 必须内置一个能够模拟物理世界的可微分模型**（JEPA 风格的），而不是一个超级大的统计语言模型。10 亿美元的融资就是用来建这个替代路线的基础设施。

第二种声音：LLM 加多模态，融合就够了

这是 Google DeepMind 的路线。Demis Hassabis 在 2025 年的访谈中明确表示，Gemini 的演进方向就是“成为世界模型”，但实现方式是在大型多模态 LLM 上叠加具身推理能力，而不是推翻生成式范式另起炉灶。

逻辑是：LLM 已经积累了人类几千年书写知识的压缩表示，在这个基础上叠加视觉、空间感知、强化学习，比从头建一套新架构更务实。Gemini Robotics 和 GPT-4o 的多模态能力，都是这个方向的体现。

这条路线有一个实用主义的支撑论据：LLM 在常识推理、语言指令理解、跨任务泛化上已经足够强，而这些恰恰是纯 RSSM/JEPA 架构最弱的地方。Gemini Robotics 的思路是：不需要从零建立物理直觉，直接借用 LLM 里已经压缩好的“世界常识”，再让模型学会把这些常识映射到连续的物理动作上。

但这条路线的批评者也有具体的论据：LLM 学到的是统计关联，不是因果结构。它能告诉你“玻璃杯掉下来会碎”，但不知道为什么碎、碎成几片、碎片会弹到哪里。这种“知道结果但不懂机制”的理解方式，在语言任务里够用，在机器人操作里可能恰好踩中最难的那块：你需要的不是常识，是精确的物理预测。

这段话呈现的是第二种声音：**不推翻 LLM，而是在 LLM 基础上叠加多模态和物理推理能力，认为“融合就够了”**。代表人物是 Google DeepMind 的 Demis Hassabis。下面我来帮你拆解这条路线的逻辑、支撑论据，以及批评者的具体反驳。

1. 这条路线的核心主张

Gemini 的演进方向就是“成为世界模型”，但实现方式是在大型多模态 LLM 上叠加具身推理能力，而不是推翻生成式范式另起炉灶。

- **不否定世界模型的目标**：DeepMind 也认为 AI 最终需要理解物理世界、能做规划和推理。
- **但反对另起炉灶**：不赞成 LeCun 那套“LLM 是弯路，要重新从连续感官信号建 JEPA”的激进路线。
- **具体做法**：把现有的、已经训练好的 LLM 作为基础，然后**加上**视觉、空间感知、强化学习等模块，让一个大的多模态模型（如 Gemini、GPT-4o）同时处理语言、图像、视频、动作。

2. 为什么他们觉得这样更务实？

“LLM 已经积累了人类几千年书写知识的压缩表示，在这个基础上叠加视觉、空间感知、强化学习，比从头建一套新架构更务实。”

支撑论据（实用主义）：

1. LLM 的常识推理已经很强：

- LLM 知道“杯子掉地上会碎”、“火是热的”、“冰箱是用来保鲜的”。这些虽然不是精确物理方程，但足够支撑很多日常任务的语言理解和简单规划。
- 这些知识来自人类几千年的文字记录，相当于一个巨大的**先验常识库**。丢掉它重头训练物理世界模型，在工程上非常低效。

2. LLM 在多模态任务中已经展现泛化能力：

- Gemini Robotics 和 GPT-4o 能够理解“把红色的苹果放到碗里”，并控制机械臂完成动作。
- 这说明 LLM 内部已经隐含了一定的空间关系和物体属性表征，只需通过微调或适配器就能映射到连续动作。

3. 工程现实：

- 从头训练一个世界模型（如 Dreamer 系列）需要大量精心设计的模拟环境和奖励函数，而且很难泛化到开放世界。
- 而 LLM 已经在大规模互联网数据上预训练完成，企业有现成的基础设施。叠加新能力的成本远低于重写范式。

3. 批评者的具体反驳（也是这段话后半部分的核心）

“LLM 学到的是统计关联，不是因果结构。它能告诉你‘玻璃杯掉下来会碎’，但不知道为什么碎、碎成几片、碎片会弹到哪里。”

批评者（主要是 LeCun 阵营以及一些机器人学研究者）的论据：

能力	LLM 的表现	物理世界模型应有的表现
因果理解	知道“A 通常导致 B”，但不知道 为什么 。	知道力的传递、材料的断裂阈值、几何约束等机制。
精确预测	只能给出模糊的、常识性的结论（“会碎”）。	能预测“以 2 m/s 撞击地面，杯子裂成 3 块，最大碎片飞向 1 米外”。
反事实推理	很难回答“如果杯子换成钢的会怎样”这类假设问题。	可以通过改变参数（材质、速度）重新模拟，得到新结果。
长尾场景	在训练数据覆盖不足时胡编（幻觉）。	即使没有数据，基于物理规律仍能做出合理外推。

具体到机器人操作：

- 你需要抓一个易碎的玻璃杯。LLM 知道“易碎”，但它不知道**用多大力度会捏碎、在哪个角度抓握最安全、如果打滑碎片会飞向哪里**。
- 这些恰恰是机器人控制中**最需要的精确物理预测**。如果世界模型不准确，机器人就会用错误的方式执行任务——比如用力过猛捏碎杯子，或者因为害怕弄碎而抓得太松导致掉落。

结论（批评者）：

“这种‘知道结果但不懂机制’的理解方式，在语言任务里够用，在机器人操作里可能恰好踩中最难的那块：你需要的不是常识，是精确的物理预测。”

4. 两种声音的核心分歧对比

维度	第一种声音 (LeCun / 谢赛宁)	第二种声音 (Hassabis / DeepMind)
对 LLM 的态度	语言是“鸦片”，是歧路	语言是宝贵的先验知识库

维度	第一种声音 (LeCun / 谢赛宁)	第二种声音 (Hassabis / DeepMind)
实现路径	从头建非生成式世界模型 (JEPA)	在 LLM 上叠加多模态和具身能力
核心能力来源	从连续感官信号中学习因果物理	从人类语言中压缩的常识 + 少量物理调优
对“智能”的定义	必须能预测物理世界、做反事实推理	能进行跨任务泛化、语言交互、常识推理
最大风险	知识从零学，数据效率低，可能失败	物理预测不够精确，机器人操作会出错
代表融资/产品	AMI Labs (10亿美元, JEPA)	Gemini Robotics, GPT-4o

5. 如何理解这种分歧的实质？

这本质上是对“智能的基础是什么”的两种回答：

- **LeCun 派**：基础是**物理世界的预测能力**。语言只是这个基础之上的一个接口。丢掉物理预测，只在语言上修修补补，永远造不出真正的智能（尤其是有身体、要操作的智能）。
- **Hassabis 派**：基础是**人类积累的知识（通过语言编码）**。物理预测只是其中一个能力，可以通过多模态训练和强化学习后加到已有的大模型上。重头学物理既不必要也不现实。

一个比喻：

- LeCun 说：要建一栋楼，必须从打地基（物理世界模型）开始，现在的 LLM 只是在半空中搭积木。
- Hassabis 说：已经有一栋很高的楼了（LLM），现在给它装上电梯和机械臂（多模态、机器人），就能用。拆了重盖太笨。

第三种声音：方向也许对，但时机还没到

这是目前最少被公开讨论、在业界却私下流传最广的一种判断。

核心是一个**数据密度问题**：语言的每个 token 携带极高的语义密度，一句话就能传达完整的命题。视觉信号截然不同：一帧 1080p 视频包含约 600 万像素，但其中承载的命题性信息（谁、在哪、做什么）压缩成文字不过几十个词。用同等数据量训练，视觉信号能传达的语义量远小于文字：语义密度低，意味着相同的命题需要更多帧才能学到。世界模型恰恰需要大量视觉输入，这意味着要训练出能力对标当前 LLM 的世界模型，所需数据量和算力可能比 LLM 高出好几个数量级，产出的能力却可能还不如一个早期的 BERT。

历史教训不止一次：NLP 领域几十年的语法树、依存句法、词性标注研究，LLM 出来之后几乎整个作废，当年写这些工具的人不是方向错了，是被规模定律碾过去了（The Bitter Lesson, Sutton, 2019）。**脉冲神经网络 (SNN)** 最接近生物神经元的工作方式，研究了将近半个世纪，Transformer 出来之后在几乎所有基准上被直接越过，连追赶的机会都没有。

持这种观点的人不反对世界模型的方向，他们反对的是现在就大规模押注：在视觉数据密度问题没有根本突破之前，所需的目标函数、计算规模、数据量都还远远不够，这个问号值得每一个认真考虑“要不要押注世界模型”的人先想清楚。

三种声音不是非此即彼。LeCun 和谢赛宁在用融资和职业生涯押注方向；DeepMind 在用工程路径逼近同一个目标；怀疑者在追问“就算方向对，现在的条件够吗”。这三个都是真问题：方向已经进入主流，但胜负还没分。

1. 核心论点：数据密度问题

“语言的每个 token 携带极高的语义密度，一句话就能传达完整的命题。视觉信号截然不同：一帧 1080p 视频包含约 600 万像素，但其中承载的命题性信息压缩成文字不过几十个词。”

数据密度 (semantic density)：单位数据量（例如一个 token 或一帧图像）所能表达的**有效命题信息**（谁、在哪、做什么、为什么）。

- **语言**：一个词或一个字符就能触发大量关联知识。“苹果”这个词可以让你联想到颜色、形状、味道、用途。所以语言模型可以用相对少量的文本学到极丰富的语义。
- **视觉**：一帧高清画面有数百万像素，但其中大部分是冗余信息（背景纹理、光照渐变）。真正有“意义”的变化往往只占很小一部分。为了获取同等的命题信息，你需要处理成百上千帧视频，才能提取出“一个人在把杯子从桌子左边移到右边”这一句话就能说完的内容。

结论：

“用同等数据量训练，视觉信号能传达的语义量远小于文字。”

因此，要训练出一个能力对标当前 LLM 的世界模型，所需的数据量和算力可能比 LLM **高出好几个数量级**，产出的能力却可能还不如一个早期的 BERT。

这就是“时机未到”的核心物理约束：**视觉数据的信噪比（语义/像素）极低**。除非我们找到一种**远超当前自监督学习的高效表征提取方法**，否则用现在的硬件和算法押注世界模型，可能会被规模定律碾压。

2. 历史教训：The Bitter Lesson 与脉冲神经网络

文章举了两个历史例子，说明“方向对但时机错”的悲剧。

2.1 The Bitter Lesson（苦涩的教训）

- **来源**：Rich Sutton 2019 年经典文章。核心观点：AI 领域几十年的进步反复证明，**利用大规模计算的方法最终会战胜那些利用人类知识精巧设计的方法**。
- **例子**：
 - 国际象棋：早期用人类开局库、残局表；后来 AlphaZero 从零自对弈，只用算力碾压。
 - 自然语言处理：几十年研究语法树、依存句法、词性标注；GPT 出来之后，这些手工特征几乎全部作废。
- **教训**：那些被碾压的学者不是方向错了（理解句法确实有用），而是他们试图用有限的算力、精巧的手工设计来对抗**规模法则**。当算力爆炸式增长时，简单的学习+海量数据+大模型就会把精心设计的特征系统淹没。

应用到世界模型：

现在投入巨资设计复杂的 JEPA、RSSM、物理归纳偏置，会不会也被未来某天的一个“视频版 GPT”直接越

过？如果“大力出奇迹”在视觉领域同样适用，那么现在押注精巧架构可能就是重蹈句法树的覆辙。

2.2 脉冲神经网络（SNN）

- SNN：模拟生物神经元的电脉冲发放，被认为是最接近大脑工作方式的模型。研究持续了将近半个世纪。
- 结局：Transformer 出来之后，在几乎所有基准上被直接越过，连追赶的机会都没有。不是因为 SNN 方向不对（生物大脑确实用脉冲），而是因为**当前的硬件（GPU）和训练算法（反向传播）与 SNN 不匹配**。等到硬件成熟了，Transformer 已经占据了所有生态位。

类比：

世界模型的方向很可能正确（最终智能需要物理理解），但现在的主流硬件（GPU 优化的是稠密矩阵乘法，而不是物理模拟的稀疏、因果结构）和主流算法（梯度下降优化的是统计似然，而不是因果图）可能还不适合大规模训练世界模型。等到光子计算、神经形态芯片成熟，也许已经有更简单的办法解决这个问题了。

3. 这种声音的实质主张

“不反对世界模型的方向，反对的是现在就大规模押注。”

- **不否定终极目标**：同意 AI 最终需要世界模型。
- **质疑当前时机**：在数据密度问题没有根本突破（例如新的自监督目标、新的数据表示、新的硬件加速物理模拟）之前，现在投入数百亿美元去建 JEPA 或扩散世界模型，可能就像 1990 年代花巨资研究 SNN 一样——方向对，但周期比你想象的长得多，而且中途会被“规模定律”奇袭。

具体建议（隐含）：

- 应该继续优化 LLM + 多模态的融合路线（第二种声音），因为这条路在现有硬件和数据条件下效率最高。
- 对纯世界模型的投入保持“战略性观察”，而不是 All in。
- 等待某个“ImageNet 时刻”出现——即视觉自监督学习在语义密度上取得数量级突破，或者出现专门为物理模拟设计的新型芯片。

4. 三种声音的对比总结

声音	核心判断	押注方向	风险
第一种（LeCun/谢赛宁）	世界模型是唯一正确的路，LLM 是歧路	从头建 JEPA，不依赖生成式	可能被规模定律碾压，工程周期长
第二种（Hassabis/DeepMind）	LLM + 多模态融合就够了	在现有 LLM 上叠加视觉和动作	物理预测不精确，机器人操作失败

声音	核心判断	押注方向	风险
第三种（怀疑论者）	方向对，但时机未到	观望，优先发展 LLM+多模态，等待视觉数据密度突破	错失先机，或者被其他人的突破打乱

文章说这三者“不是非此即彼”，因为它们回答的是不同层次的问题：

- 第一种回答“**终极目标是什么**”（物理世界模型）。
- 第二种回答“**当下工程最优解是什么**”（LLM 扩展）。
- 第三种回答“**投资回报周期有多长**”（可能比想象的长得多）。

八、结语

从 Craik 在 1943 年写下“**颅骨里的小模型**”，到 2026 年 DreamDojo 从人类视频里教会机器人拧螺丝，这条线索走了 80 年，始终指向同一个问题：**智能体怎么在行动之前先想清楚？**

LLM 回答的是“世界是什么样的”，世界模型回答的是“如果我这样做，世界会发生什么”。这是两个不同的问题，目前没有任何一种架构同时把两者都解决好了。

随着机器人和具身智能从实验室走向现实，第二个问题会越来越重要。

如果你对这条技术路线感兴趣，想从零开始动手实现，从 VAE 编码器到完整的 Dreamer 流水线，Datawhale 正在开源一套配套课程和代码 📌：

github.com/datawhalechina/learn-world-model

欢迎 star、fork、一起共建。

Datawhale
和学习者一起成长

一个专注于AI的开源组织，让学习不再孤独



长按扫码关注我們